

Modeling Poverty Rates in Indonesian Regencies and Cities Using a Bayesian Generalized Additive Model

Pemodelan Persentase Penduduk Miskin Kabupaten/Kota di Indonesia Menggunakan *Bayesian Generalized Additive Model*

Muhammad Fauzan Nur Rasendriya^{1*}, Rafi Adabhi Sunarya², Nika Restu Widya Mujianasta³, Zanira Husna⁴, Agustin Salsabilla⁵, Laily Nissa Atul Mualifah⁶, Kusman Sadik⁷, Anang Kurnia⁸, Anik Djuraidah⁹

^{1,2,3,4,5,6,7,8,9} Statistics dan Data Science Study Program, IPB University, Indonesia

Email: rasendriyafauzan@apps.ipb.ac.id¹, 31052006adabhi@apps.ipb.ac.id², nikarstwidya@apps.ipb.ac.id³, seventeen.husna@apps.ipb.ac.id⁴, agustinsalsabilla@apps.ipb.ac.id⁵, laylatul@apps.ipb.ac.id⁶, kumans@apps.ipb.ac.id⁷, anangk@apps.ipb.ac.id⁸, anikdjuraidah@apps.ipb.ac.id⁹

*Corresponding author

Abstract

Poverty remains a major development challenge in Indonesia due to substantial disparities across regions. The relationship between poverty and socioeconomic indicators is often complex and may not follow a simple linear pattern. This study aims to model poverty rates in Indonesian regencies and cities using a Bayesian Generalized Additive Model (Bayesian GAM) capable of capturing nonlinear relationships. The analysis was conducted using cross-sectional data from 514 regencies and cities in Indonesia in 2024. The response variable was the percentage of poor population, while the predictors included regional gross domestic product (GRDP), life expectancy, and average years of schooling. Exploratory analysis indicated that the response variable was positive and right-skewed; therefore, a Gamma distribution with a log link function was adopted. Nonlinear effects were modeled using penalized splines (P-splines), and *posterior* estimation was performed through Hamiltonian Monte Carlo with the No-U-Turn Sampler algorithm. Model adequacy was evaluated using convergence diagnostics, *posterior* predictive checks, and Bayesian R-squared. The results showed that all MCMC chains converged successfully with R-hat values ranging from 0.9997 to 1.0045. *Posterior* predictive checks indicated that the model adequately reproduced the observed data distribution. The Bayesian R-squared value was estimated at 0.624 (95% credible interval: 0.547–0.676), indicating that the model explained approximately 62.4% of the variation in poverty rates. Conditional effect analysis revealed negative and nonlinear relationships between poverty and all predictors. The strongest reductions in poverty occurred at lower levels of regional economic performance, life expectancy, and educational attainment, while the marginal effects gradually diminished at higher levels. These findings suggest that *Bayesian GAM* provides a flexible framework for identifying nonlinear socioeconomic determinants of poverty and may support more targeted poverty reduction policies.

Keywords: Bayesian GAM, poverty, P-spline, Gamma regression, socioeconomic indicators

Abstrak

Kemiskinan masih menjadi salah satu tantangan utama pembangunan di Indonesia karena terdapat perbedaan kondisi sosial-ekonomi yang cukup besar antarwilayah. Hubungan antara kemiskinan dan

indikator sosial-ekonomi sering kali bersifat kompleks dan tidak selalu mengikuti pola linier sederhana. Penelitian ini bertujuan memodelkan persentase penduduk miskin kabupaten/kota di Indonesia menggunakan *Bayesian Generalized Additive Model (Bayesian GAM)* yang mampu menangkap hubungan nonlinier. Data yang digunakan merupakan data *cross-sectional* tahun 2024 dengan unit analisis sebanyak 514 kabupaten/kota di Indonesia. Variabel respons adalah persentase penduduk miskin, sedangkan variabel penjelas meliputi Produk Domestik Regional Bruto (PDRB) regional, angka harapan hidup, dan rata-rata lama sekolah. Hasil eksplorasi menunjukkan bahwa variabel respons bernilai positif dan menceng ke kanan sehingga digunakan distribusi Gamma dengan fungsi penghubung log. Efek nonlinier dimodelkan menggunakan *penalized spline (P-spline)*, sedangkan estimasi *posterior* dilakukan menggunakan Hamiltonian Monte Carlo dengan algoritma No-U-Turn Sampler. Evaluasi model dilakukan melalui diagnostik konvergensi, *posterior predictive check*, dan *Bayesian R-squared*. Hasil penelitian menunjukkan bahwa seluruh rantai MCMC mencapai konvergensi yang baik dengan nilai *R-hat* antara 0,9997 hingga 1,0045. *Posterior predictive check* menunjukkan bahwa model mampu mereproduksi distribusi data observasi dengan baik. Nilai *Bayesian R-squared* sebesar 0,624 (interval kredibel 95%: 0,547–0,676) menunjukkan bahwa model mampu menjelaskan sekitar 62,4% variasi persentase penduduk miskin. Analisis efek kondisional menunjukkan bahwa PDRB regional, angka harapan hidup, dan rata-rata lama sekolah memiliki hubungan negatif dan nonlinier terhadap kemiskinan. Penurunan kemiskinan paling besar terjadi pada wilayah dengan kondisi awal yang masih rendah, sedangkan efek marginalnya cenderung melandai pada wilayah yang lebih maju. Temuan ini menunjukkan bahwa *Bayesian GAM* merupakan pendekatan yang fleksibel untuk mengidentifikasi hubungan nonlinier faktor sosial-ekonomi terhadap kemiskinan dan dapat mendukung perumusan kebijakan pengentasan kemiskinan yang lebih tepat sasaran.

Kata kunci: *Bayesian GAM*, kemiskinan, *P-spline*, regresi Gamma, indikator sosial-ekonomi

1. PENDAHULUAN

Kemiskinan merupakan persoalan pembangunan yang tidak semata terkait dengan rendahnya pendapatan, melainkan juga berkaitan dengan keterbatasan akses terhadap pendidikan, kesehatan, pekerjaan layak, serta kesempatan ekonomi. Dalam kerangka Tujuan Pembangunan Berkelanjutan, pengentasan kemiskinan ditetapkan sebagai tujuan pertama yang perlu diupayakan secara beriringan dengan peningkatan kualitas pendidikan, kesehatan, dan pertumbuhan ekonomi yang inklusif [16]. Di Indonesia, persoalan ini tetap relevan untuk dikaji mengingat penurunan tingkat kemiskinan secara nasional belum sepenuhnya mampu menghapus kesenjangan kondisi antarwilayah. Badan Pusat Statistik [2] mencatat bahwa persentase penduduk miskin pada Maret 2024 berada pada angka 9,03%, mengalami penurunan dibandingkan periode sebelumnya. Meskipun demikian, publikasi data kemiskinan tingkat kabupaten/kota mengindikasikan bahwa variasi antarwilayah masih memerlukan perhatian khusus dalam perumusan kebijakan berbasis data [3].

Disparitas tingkat kemiskinan antarkabupaten/kota dapat dipengaruhi oleh beragam faktor sosial dan ekonomi. Produk Domestik Regional Bruto (PDRB) merepresentasikan kapasitas ekonomi wilayah, sementara angka harapan hidup dan rata-rata lama sekolah masing-masing menggambarkan dimensi modal manusia dari aspek kesehatan dan pendidikan. Secara konseptual, wilayah dengan aktivitas ekonomi yang lebih kuat, kualitas kesehatan yang lebih baik, serta capaian pendidikan yang lebih tinggi diasumsikan memiliki tingkat kemiskinan yang relatif lebih rendah. Penelitian Sitorus, Muchtar, dan Sihombing [15] juga menunjukkan bahwa indikator pendidikan dan kesehatan berkaitan erat dengan kinerja ekonomi wilayah, sehingga ketiga dimensi tersebut relevan untuk dipertimbangkan dalam analisis kemiskinan daerah.

Sejumlah penelitian sebelumnya telah mengkaji keterkaitan antara pertumbuhan ekonomi, pendidikan, kesehatan, dan kemiskinan. Alim dan Harsono [1] menganalisis kemiskinan di Provinsi Nusa

Tenggara Barat tahun 2015-2024 menggunakan regresi data panel dan menemukan bahwa pertumbuhan ekonomi, pendidikan, dan kesehatan secara simultan berhubungan dengan kemiskinan. Fernando dan Samsuddin [7] menggarisbawahi peran penting pendidikan dan kesehatan dalam menjelaskan tingkat kemiskinan di Indonesia. Sementara itu, Fauzan, Istikomah, Kurniawati, dan Machmud [6] mengkaji peran modal manusia berbasis pendidikan dan kesehatan terhadap kemiskinan pada 34 provinsi di Indonesia. Temuan-temuan tersebut memperkuat argumen bahwa kemiskinan tidak dapat dipahami hanya melalui satu dimensi ekonomi, melainkan perlu dianalisis melalui kombinasi indikator ekonomi dan modal manusia secara terintegrasi.

Meskipun demikian, mayoritas penelitian terdahulu masih mengandalkan pendekatan regresi linier atau regresi panel yang mengasumsikan bahwa pengaruh prediktor terhadap kemiskinan bersifat konstan di sepanjang rentang data. Asumsi tersebut berpotensi terlalu menyederhanakan persoalan, mengingat hubungan antara PDRB, pendidikan, kesehatan, dan kemiskinan dimungkinkan bersifat nonlinier. Sebagai ilustrasi, peningkatan PDRB pada wilayah dengan kondisi ekonomi yang masih rendah berpotensi memberikan dampak penurunan kemiskinan yang lebih signifikan dibandingkan peningkatan PDRB pada wilayah yang telah maju. Pola serupa juga memungkinkan akan terjadi pada indikator kesehatan dan pendidikan, di mana manfaat marginal cenderung lebih besar dirasakan oleh wilayah dengan capaian awal yang masih rendah. Simanjuntak [14] telah mengaplikasikan *Generalized Additive Model* (GAM) dalam kajian kemiskinan dengan pendekatan nonlinier, namun kajian tersebut masih terbatas pada lingkup DKI Jakarta dan belum mengadopsi kerangka *Bayesian* untuk mengukur ketidakpastian *posterior* secara komprehensif.

Berdasarkan kesenjangan penelitian tersebut, studi ini mengaplikasikan *Bayesian Generalized Additive Model* (*Bayesian GAM*) untuk menganalisis hubungan antara persentase penduduk miskin dengan PDRB regional, angka harapan hidup, dan rata-rata lama sekolah pada 514 kabupaten/kota di Indonesia. GAM dipilih karena kapabilitasnya dalam memodelkan hubungan nonlinier melalui fungsi *smooth* [10, 18] sementara pendekatan *Bayesian* diterapkan guna memperoleh estimasi *posterior* dan interval kredibel yang merepresentasikan ketidakpastian parameter secara lebih eksplisit [4, 17]. Dengan demikian, penelitian ini tidak hanya menilai arah hubungan antarvariabel, tetapi juga mengidentifikasi bentuk hubungan nonlinier beserta tingkat ketidakpastian estimasinya.

Penelitian ini bertujuan untuk memodelkan persentase penduduk miskin kabupaten/kota di Indonesia menggunakan *Bayesian GAM* berbasis *P-spline* dengan distribusi Gamma dan fungsi penghubung log. Secara lebih spesifik, penelitian ini bertujuan untuk mendeskripsikan karakteristik persentase penduduk miskin, PDRB regional, angka harapan hidup, dan rata-rata lama sekolah, menentukan kesesuaian distribusi respons bagi data kemiskinan yang bernilai positif dan menceng ke kanan, mengestimasi model *Bayesian GAM* dengan komponen *smooth* pada setiap prediktor, mengevaluasi kecukupan model melalui diagnostik MCMC, *posterior predictive check*, dan *Bayesian R-squared*; serta menginterpretasikan pola hubungan nonlinier antara indikator ekonomi dan modal manusia terhadap persentase penduduk miskin.

2. METODOLOGI PENELITIAN

2.1. Data dan Peubah Penelitian

Penelitian ini menggunakan data sekunder dari Badan Pusat Statistik, tingkat kabupaten/kota di Indonesia tahun 2024 dengan unit analisis sebanyak 514 observasi. Variabel respons yang dianalisis adalah persentase penduduk miskin, sedangkan variabel penjelas yang digunakan meliputi PDRB regional, angka harapan hidup, dan rata-rata lama sekolah. PDRB regional digunakan sebagai indikator kondisi ekonomi wilayah, angka harapan hidup digunakan sebagai indikator kondisi kesehatan, sedangkan rata-rata lama sekolah digunakan sebagai indikator pendidikan.

Tabel 1. Daftar peubah yang digunakan dalam penelitian

Peubah	Nama Variabel	Keterangan	Satuan
Y	Persentase Kemiskinan	Persentase penduduk miskin kabupaten/kota	Persen (%)
X1	PDRB	PDRB regional kabupaten/kota	miliar rupiah
X2	Angka Harapan Hidup	Rata-rata angka harapan hidup laki-laki dan perempuan	Tahun
X3	Rata Lama Sekolah	Rata-rata lama sekolah penduduk	Tahun

2.2. Generalized Additive Model (GAM)

Generalized Additive Model (GAM) merupakan perluasan dari Generalized Linear Model yang memungkinkan hubungan antara respons dan prediktor dimodelkan secara fleksibel melalui fungsi halus [10]. Jika pada model linier pengaruh prediktor diasumsikan berbentuk garis lurus, maka pada GAM pengaruh tersebut dinyatakan sebagai fungsi smooth sehingga mampu menangkap pola hubungan yang menurun, melandai, atau berubah kemiringan sepanjang rentang data [18].

$$g(\mu_i) = \alpha + f_1(x_{i1}) + f_2(x_{i2}) + \dots + f_p(x_{ip}) \quad (2.1)$$

dengan μ_i menyatakan nilai harapan respons pada observasi ke- i , $g(\cdot)$ merupakan fungsi penghubung, α merupakan intersep, dan $f_j(\cdot)$ merupakan fungsi smooth untuk prediktor ke- j . Pada penelitian ini, fungsi smooth digunakan untuk log PDRB regional, angka harapan hidup, dan rata-rata lama sekolah.

2.3. Spesifikasi Model Bayesian GAM

Berdasarkan hasil eksplorasi distribusi respons, model akhir dibangun menggunakan distribusi Gamma dengan fungsi penghubung log. Secara umum, model *Bayesian GAM* yang digunakan dapat dituliskan sebagai berikut.

$$Y_i \sim \text{Gamma}(\mu_i, \nu) \quad (2.3)$$

$$\log(\mu_i) = \alpha + f_1(\log(\text{PDRB})_i) + f_2(\text{AHH}_i) + f_3(\text{RLS}_i) \quad (2.4)$$

dengan Y_i merupakan persentase penduduk miskin pada kabupaten/kota ke- i , μ_i merupakan rata-rata respons bersyarat, α merupakan intersep, dan shape merupakan parameter bentuk pada distribusi Gamma. Fungsi f_1 , f_2 , dan f_3 masing-masing merepresentasikan efek nonlinier dari log PDRB regional, angka harapan hidup, dan rata-rata lama sekolah.

Tabel 2. Distribusi prior model *Bayesian GAM*

Parameter	Prior
Intercept	Normal(0, 5)
Koefisien basis spline	Normal(0, 5)
Shape Gamma	Exponential(1)
Smooth term SD	Exponential(1)

Prior Normal(0,5) untuk intersep dan koefisien basis *spline* dipilih sebagai prior *weakly informative* yang cukup lebar untuk tidak mendominasi informasi dari data, namun tetap membatasi ruang parameter pada nilai yang masuk akal pada skala log. Prior *Exponential*(1) untuk parameter *shape* Gamma dan *smooth*

term SD dipilih karena kedua parameter tersebut bernilai positif, di mana distribusi *Exponential* secara alami membatasi ruang parameter pada domain positif sekaligus memberi bobot lebih besar pada nilai kecil, sehingga mendorong model ke arah *smoothing* yang lebih sederhana, kecuali data menunjukkan bukti kuat sebaliknya.

Berbeda dengan GAM klasik yang mengestimasi parameter smoothing melalui maksimisasi *likelihood* terpenalti (penalized likelihood) dan menghasilkan estimasi titik beserta selang kepercayaan berbasis pendekatan asimtotik, *Bayesian* GAM memperlakukan tingkat kehalusan (*smoothness*) kurva sebagai bagian dari struktur prior, yang direpresentasikan oleh *smooth term* SD pada Tabel 2. Dengan demikian, ketidakpastian parameter *smoothing* turut diestimasi secara simultan melalui distribusi *posterior*, bukan diasumsikan tetap sebagaimana pada GAM klasik.

2.5. Estimasi Posterior dengan HMC-NUTS

Estimasi *posterior* dilakukan menggunakan Hamiltonian Monte Carlo (HMC) dengan algoritma No-U-Turn Sampler (NUTS) [11]. HMC memanfaatkan informasi gradien dari log *posterior* untuk mengeksplorasi ruang parameter secara lebih efisien dibandingkan random-walk MCMC, sedangkan NUTS secara adaptif menentukan panjang lintasan simulasi sehingga proses sampling tidak perlu menentukan jumlah langkah *leapfrog* secara manual.

$$p(\theta | y) \propto p(y | \theta) p(\theta) \quad (2.5)$$

dengan θ mencakup seluruh parameter model, $p(y | \theta)$ merupakan likelihood Gamma, dan $p(\theta)$ merupakan gabungan prior. Pada analisis ini, sampling dilakukan menggunakan empat rantai MCMC, masing-masing 2000 iterasi dengan 1000 iterasi *warm-up* dan 1000 iterasi sampling, sehingga diperoleh 4000 sampel *posterior*. Pengaturan *adapt_delta* = 0,999 dan *max_treedepth* = 12 digunakan untuk meningkatkan stabilitas sampling pada model smooth nonlinier [4].

2.5. Diagnostik dan Evaluasi Model

Diagnostik model dilakukan untuk memastikan bahwa sampel *posterior* yang diperoleh layak digunakan untuk inferensi. Konvergensi MCMC diperiksa menggunakan nilai $\hat{R}$, model dianggap memiliki konvergensi yang baik apabila nilai $\hat{R}$ mendekati satu dan tidak melebihi ambang umum 1,01. Efisiensi sampling diperiksa melalui effective sample size ratio [17].

$$\hat{R} = \sqrt{\frac{\widehat{\text{Var}}^+(\theta|y)}{W}} \quad (2.6)$$

$$S_{\text{eff}} = \frac{nm}{1 + 2 \sum_{t=1}^{\infty} \hat{\rho}_t} \quad (2.7)$$

dengan $\hat{\rho}_t$ autokorelasi sampel pada lag t . Bulk- S_{eff} dan tail- S_{eff} dihitung berdasarkan rank-normalized draws mengikuti prosedur Vehtari et al. [17], sebagai penyempurnaan dari formula ESS klasik di atas. Nilai ESS yang tinggi menunjukkan kualitas estimasi *posterior* yang lebih baik dan tingkat autokorelasi yang rendah. Selain diagnostik MCMC, kecukupan model dievaluasi menggunakan *posterior predictive check* (PPC), yaitu membandingkan distribusi data observasi dengan data replikasi yang dibangkitkan dari *posterior* prediktif [9]. Model yang baik diharapkan mampu mereproduksi pola utama data, terutama bentuk distribusi, pusat sebaran, dan keragamannya. Kinerja penjelasan model juga diringkas menggunakan *Bayesian R-squared* [8].

$$R^2_{\text{Bayes}} = \frac{\text{Var}(\hat{y})}{\text{Var}(\hat{y}) + \text{Var}(e)} \quad (2.8)$$

2.7. Langkah Penelitian


Langkah analisis dalam penelitian ini dilakukan secara runtut sebagai berikut:

1. Mengumpulkan data sekunder kabupaten/kota di Indonesia tahun 2024.
2. Melakukan statistik deskriptif untuk variabel persentase penduduk miskin, PDRB regional, angka harapan hidup, dan rata-rata lama sekolah.
3. Mengeksplorasi sebaran variabel respons menggunakan histogram, kurva kepadatan, *boxplot*, QQ plot, dan perbandingan distribusi Normal-Gamma.
4. Mentransformasi PDRB regional menggunakan logaritma natural karena distribusinya sangat menceng ke kanan.
5. Mengeksplorasi hubungan antara variabel respons dan setiap prediktor menggunakan scatter plot, garis regresi linear, dan kurva LOESS.
6. Memeriksa korelasi antar prediktor untuk memastikan tidak terdapat indikasi multikolinearitas yang serius.
7. Membangun model *Bayesian* GAM dengan distribusi Gamma dan fungsi *link* log.
8. Memodelkan setiap prediktor menggunakan komponen smooth *P-spline* dengan $k = 10$ dan penalti orde kedua.
9. Menetapkan prior lemah-informatif untuk intersep, koefisien basis spline, parameter shape, dan smooth term SD.
10. Mengestimasi *posterior* menggunakan HMC-NUTS dengan empat rantai MCMC, 2000 iterasi per rantai, 1000 *warm-up*, *adapt_delta* = 0,999, dan *max_treedepth* = 12.
11. Mengevaluasi konvergensi model melalui R-hat dan effective sample size ratio.
12. Melakukan *posterior predictive check* untuk menilai kemampuan model mereproduksi distribusi data observasi.
13. Menghitung *Bayesian R-squared* sebagai ukuran kemampuan model menjelaskan variasi respons.
14. Menginterpretasikan efek nonlinier setiap prediktor melalui conditional effects dengan interval kredibel 95%.

3. HASIL DAN PEMBAHASAN


3.1. Eksplorasi Data

Eksplorasi data dilakukan untuk memahami karakteristik variabel penelitian sebelum pemodelan. Eksplorasi bertujuan untuk mengidentifikasi pola sebaran data, keberadaan pencilan, serta karakteristik distribusi masing-masing variabel. Gambar 1 menyajikan *boxplot* persentase penduduk miskin, PDRB regional, angka harapan hidup, dan rata-rata lama sekolah pada 514 kabupaten/kota di Indonesia.



Gambar 1. *Boxplot* sebaran variabel penelitian

Gambar 1 menunjukkan bahwa PDRB regional memiliki sebaran yang sangat lebar dengan pencilan ekstrem pada nilai tinggi, yang mengindikasikan distribusi menceng ke kanan. Persentase penduduk miskin juga memiliki beberapa observasi bernilai tinggi, sedangkan angka harapan hidup dan rata-rata lama sekolah cenderung lebih stabil dengan variasi yang lebih kecil. Oleh karena itu, transformasi logaritma diterapkan pada PDRB regional untuk mengurangi pengaruh kemencengan dan pencilan ekstrem..




Gambar 2. Distribusi persentase penduduk miskin

Distribusi persentase penduduk miskin pada Gambar 2 menunjukkan pola menceng ke kanan dengan puncak distribusi pada kisaran 6% hingga 8% dan ekor kanan yang memanjang hingga di atas 40%. Sebagian besar observasi terkonsentrasi pada tingkat kemiskinan yang relatif rendah, sedangkan hanya sedikit wilayah yang memiliki tingkat kemiskinan sangat tinggi. Selain itu, seluruh nilai observasi berada pada domain positif. Karakteristik tersebut mengindikasikan bahwa distribusi data tidak simetris sehingga asumsi distribusi Normal kurang sesuai untuk merepresentasikan variabel respons.


3.2. Pemilihan Distribusi Respons dan Pola Hubungan Antarvariabel

Berdasarkan hasil eksplorasi data, perlu dilakukan analisis lebih lanjut terhadap distribusi variabel respons dan pola hubungan antara persentase penduduk miskin dengan variabel penjelas. Tahap ini dilakukan untuk memberikan dasar empiris dalam pemilihan distribusi respons, fungsi penghubung, serta bentuk hubungan yang digunakan pada model *Bayesian Generalized Additive Model* (GAM).



Gambar 3. Perbandingan distribusi Normal dan Gamma


Berdasarkan QQ plot dan kurva kepadatan pada Gambar 3, distribusi Gamma lebih sesuai dalam mengikuti pola empiris persentase penduduk miskin dibandingkan distribusi Normal. Distribusi Normal menunjukkan ketidaksesuaian pada ekor kiri karena menghasilkan kuantil teoretis negatif, padahal persentase kemiskinan secara konseptual tidak mungkin bernilai negatif. Pada sisi lain, distribusi Gamma lebih sesuai untuk pola data positif yang menceng ke kanan. Oleh karena itu, keluarga Gamma dengan fungsi penghubung log digunakan dalam model *Bayesian GAM*.



Gambar 4. Hubungan persentase penduduk miskin dengan prediktor

Pola hubungan antara persentase penduduk miskin dan setiap prediktor dieksplorasi menggunakan kurva LOESS dan garis regresi linier. Gambar 4 menunjukkan bahwa hubungan antara prediktor dan persentase penduduk miskin tidak sepenuhnya linier. Pada PDRB skala asli, sebagian besar observasi terkonsentrasi di dekat nol akibat adanya beberapa wilayah dengan PDRB yang sangat tinggi. Setelah ditransformasi menjadi log PDRB, pola hubungan menjadi lebih jelas, yaitu menurun tajam pada log PDRB rendah lalu melandai pada nilai yang lebih tinggi. Pola serupa juga terlihat pada angka harapan hidup dan rata-rata lama sekolah, di mana peningkatan kedua variabel tersebut cenderung diikuti oleh penurunan tingkat kemiskinan, meskipun perubahan kemiringan kurva menunjukkan adanya hubungan nonlinier. Perbedaan antara kurva LOESS dan garis regresi linier pada ketiga prediktor mengindikasikan bahwa hubungan tersebut tidak sepenuhnya dapat direpresentasikan oleh model linier sederhana. Hal ini menjadi

dasar empiris penggunaan fungsi *smooth* dalam *Bayesian* GAM untuk menangkap pola hubungan yang lebih fleksibel.



Gambar 5. Korelasi antarprediktor

Selanjutnya, untuk memastikan bahwa variabel penjelas dapat digunakan secara bersama-sama dalam model, dilakukan pemeriksaan korelasi antarprediktor yang disajikan pada Gambar 5. Gambar 5 menunjukkan bahwa korelasi antarprediktor berada pada tingkat rendah hingga sedang, yaitu berkisar antara 0,32 sampai 0,58. Tidak terdapat pasangan variabel dengan korelasi mendekati 0,80 sehingga tidak ditemukan indikasi multikolinearitas yang serius. Oleh karena itu, seluruh prediktor dapat dipertahankan dalam pemodelan.

3.3. Estimasi Model *Bayesian* GAM

Model *Bayesian* GAM diestimasi menggunakan distribusi Gamma dengan link log dan tiga komponen smooth berbasis *P-spline*. Setiap komponen smooth menggunakan $k = 10$ dan penalti orde kedua. Estimasi dilakukan dengan empat rantai MCMC, masing-masing 2000 iterasi dengan 1000 iterasi *warm-up* dan 1000 iterasi sampling, sehingga diperoleh 4000 sampel *posterior*. Ringkasan estimasi *posterior* disajikan pada Tabel 3.

Tabel 3. Estimasi *posterior* model *Bayesian* GAM

Parameter	<i>Estimate</i>	<i>Est.Error</i>	CI 2,5%	CI 97,5%	$\hat{R}$	<i>Bulk</i> ESS	<i>Tail</i> ESS
SD <i>smooth</i> log(PDRB)	0,08	0,05	0,02	0,21	1,00	1347	1861
SD <i>smooth</i> AHH	0,06	0,05	0,00	0,19	1,00	1174	1179
SD <i>smooth</i> RLS	0,12	0,09	0,00	0,35	1,00	589	981
Intersep	2,33	0,02	2,29	2,36	1,00	5965	3021
Basis <i>spline</i> log(PDRB)	-0,20	0,06	-0,32	-0,07	1,00	2988	2546
Basis <i>spline</i> AHH	-0,10	0,06	-0,20	0,03	1,00	2314	2769
Basis <i>spline</i> RLS	-0,15	0,07	-0,28	0,00	1,00	1840	1882
<i>Shape</i> Gamma	6,00	0,38	5,29	6,77	1,00	5094	2960

Pada Tabel 3, kolom *Estimate* menunjukkan nilai tengah *posterior* atau estimasi utama dari masing-masing parameter, sedangkan *Est.Error* menunjukkan simpangan baku *posterior* yang menggambarkan ketidakpastian estimasi. Kolom CI 2,5% dan CI 97,5% merupakan batas bawah dan batas atas interval

kredibel 95%. Artinya, berdasarkan distribusi *posterior*, nilai parameter yang bersangkutan berada di antara kedua batas tersebut dengan probabilitas *posterior* sekitar 95%. Parameter *Shape* Gamma diestimasi sebesar 6,00 dengan interval kredibel 95% antara 5,29 dan 6,77, sehingga bentuk sebaran Gamma yang digunakan dalam model relatif teridentifikasi dengan baik.


Nilai SD *smooth* pada log(PDRB), angka harapan hidup (AHH), dan rata-rata lama sekolah (RLS) seluruhnya bernilai positif, yang menunjukkan adanya variasi nonlinier dalam hubungan antara prediktor dan persentase penduduk miskin. Namun, batas bawah interval kredibel untuk AHH dan RLS mendekati nol, sehingga keberadaan efek nonlinier pada kedua variabel tersebut lebih tepat dievaluasi melalui bentuk fungsi *smooth* daripada hanya berdasarkan nilai parameteranya. Nilai $\hat{R}$ sebesar 1,00 pada seluruh parameter menunjukkan bahwa rantai MCMC telah bercampur dengan baik dan tidak terdapat indikasi masalah konvergensi yang kuat.

Bulk ESS pada Tabel 3 menunjukkan jumlah sampel *posterior* efektif untuk mengestimasi bagian tengah distribusi *posterior*, seperti mean dan median. *Tail* ESS menunjukkan jumlah sampel efektif untuk bagian ekor distribusi *posterior*, sehingga berkaitan dengan keandalan interval kredibel. Nilai *Bulk* ESS dan *Tail* ESS pada sebagian besar parameter berada di atas 1000, bahkan intersep dan *Shape* Gamma memiliki ESS di atas 3000 sampai 5000, sehingga estimasi *posterior*nya stabil. Nilai *Bulk* ESS terkecil terdapat pada SD *smooth* RLS sebesar 589 dan *Tail* ESS sebesar 981; nilai ini lebih rendah dibanding parameter lain, tetapi masih cukup untuk interpretasi model karena $\hat{R}$ tetap 1,00 dan interpretasi utama efek RLS dilakukan melalui kurva efek kondisional.

Sementara itu, parameter basis spline tidak diinterpretasikan secara langsung seperti koefisien regresi linier karena berfungsi sebagai komponen pembentuk kurva *smooth*. Oleh karena itu, interpretasi substantif pengaruh masing-masing prediktor dilakukan berdasarkan bentuk fungsi *smooth* yang dibahas pada bagian analisis efek kondisional.

3.4. Diagnostik Konvergensi MCMC

Evaluasi konvergensi merupakan langkah penting untuk memastikan bahwa sampel yang dihasilkan oleh algoritma MCMC telah secara stabil merepresentasikan distribusi *posterior* dengan baik. Pemeriksaan konvergensi rantai MCMC dalam pemodelan ini didasarkan pada dua indikator utama, yaitu nilai $\hat{R}$ dan rasio *Effective Sample Size* (ESS). Hasil diagnostik konvergensi tersebut secara visual dapat dilihat pada Gambar 6 di bawah ini.




Gambar 6. Diagnostik Rhat dan ESS ratio

Berdasarkan Gambar 6, seluruh nilai $\hat{R}$ berada sangat dekat dengan satu, yaitu pada rentang 0,9997 hingga 1,0045. Hal ini menunjukkan bahwa keempat rantai MCMC telah mencapai konvergensi yang baik. Plot ESS ratio menunjukkan bahwa sebagian besar parameter memiliki efisiensi sampling yang memadai. Beberapa parameter memiliki rasio ESS yang lebih rendah, tetapi masih berada pada tingkat yang dapat diterima untuk inferensi *posterior*.

3.5. Evaluasi Kecukupan Model

Evaluasi kecukupan model dilakukan untuk menilai sejauh mana model *Bayesian GAM* mampu merepresentasikan karakteristik data yang diamati. Penilaian dilakukan melalui *posterior predictive check* dan ukuran *Bayesian R-squared*.



Gambar 7. *Posterior predictive check* model *Bayesian GAM*

Posterior predictive check pada Gambar 7 membandingkan kurva kepadatan data observasi y dengan kurva kepadatan data replikasi *posterior* y_{rep} . Pada plot ini ditampilkan 100 kurva y_{rep} yang diambil dari distribusi prediktif *posterior*, bukan seluruh 4000 sampel *posterior*, agar visualisasi tetap terbaca. Setiap kurva y_{rep} merepresentasikan satu kemungkinan data baru yang disimulasikan dari model setelah mempertimbangkan ketidakpastian *posterior*. Kurva data observasi berada di tengah kumpulan kurva y_{rep} , sehingga model mampu mereproduksi puncak distribusi serta menangkap pola kemencengan ke kanan pada data persentase penduduk miskin. Tidak terlihat penyimpangan sistematis yang kuat antara data observasi dan data replikasi *posterior*, sehingga model Gamma-log dinilai cukup memadai dalam merepresentasikan bentuk distribusi kemiskinan.

Tabel 4. *Bayesian R-squared* model


Ukuran	Estimate	Est.Error	Q2,5	Q97,5
<i>Bayesian R-squared</i>	0,624	0,033	0,547	0,676

Tabel 5 menunjukkan bahwa nilai *Bayesian R-squared* sebesar 0,624 dengan interval kredibel 95% antara 0,547 dan 0,676. Hasil tersebut menunjukkan bahwa model mampu menjelaskan sekitar 62,4% variasi persentase penduduk miskin berdasarkan log PDRB regional, angka harapan hidup, dan rata-rata lama sekolah. Nilai ini dapat dikategorikan cukup baik untuk data lintas wilayah, mengingat tingkat kemiskinan kabupaten/kota juga dipengaruhi oleh berbagai faktor lain yang tidak dimasukkan dalam model. Secara keseluruhan, hasil *posterior predictive check* dan *Bayesian R-squared* menunjukkan bahwa model *Bayesian GAM* memiliki kemampuan yang memadai dalam menggambarkan pola data dan menjelaskan variasi persentase penduduk miskin antarwilayah.

3.6. Interpretasi Efek Nonlinier

Setelah model dinyatakan memadai berdasarkan hasil diagnostik dan evaluasi kecukupan model, hubungan antara masing-masing prediktor dan persentase penduduk miskin diinterpretasikan melalui kurva efek kondisional (*conditional effects*) dari model *Bayesian* GAM. Kurva ini menunjukkan perubahan nilai prediksi *posterior* persentase penduduk miskin pada berbagai nilai prediktor dengan variabel lain dipertahankan pada nilai rata-ratanya.

Bagian abu-abu pada kurva efek kondisional menunjukkan interval kredibel 95% dari prediksi *posterior*. Semakin lebar area abu-abu, semakin besar ketidakpastian estimasi efek pada rentang prediktor tersebut. Area abu-abu yang lebih lebar pada ujung kiri atau kanan kurva umumnya terjadi karena jumlah observasi pada rentang ekstrem lebih sedikit, sehingga model memiliki informasi data yang lebih terbatas untuk mengestimasi efek pada wilayah tersebut.



Gambar 8. Efek kondisional prediktor terhadap persentase penduduk miskin

Gambar 8(a) menunjukkan bahwa log PDRB regional memiliki hubungan negatif dan nonlinier dengan persentase penduduk miskin. Pada rentang log PDRB rendah sekitar 6 sampai 9, peningkatan PDRB berkaitan dengan penurunan kemiskinan yang relatif tajam, dari sekitar 20% menjadi sekitar 9% sampai 10%. Setelah melewati rentang tersebut, kurva mulai melandai sehingga tambahan peningkatan PDRB pada wilayah yang lebih maju memberikan penurunan kemiskinan yang lebih kecil. Hal ini menunjukkan bahwa manfaat pertumbuhan ekonomi terhadap pengurangan kemiskinan cenderung lebih besar pada wilayah dengan tingkat pembangunan ekonomi yang masih rendah.

Gambar 8(b) memperlihatkan pola serupa pada angka harapan hidup. Kemiskinan diprediksi menurun dari sekitar 16% pada angka harapan hidup terendah, yaitu sekitar 55 sampai 56 tahun, menjadi sekitar 8% pada kisaran 70 sampai 72 tahun. Setelah itu, kurva cenderung stabil pada rentang 72 sampai 78 tahun. Dengan demikian, peningkatan kondisi kesehatan memiliki kaitan yang lebih besar dengan penurunan kemiskinan pada wilayah yang kondisi awalnya masih rendah.

Gambar 8(c) menunjukkan bahwa rata-rata lama sekolah juga berhubungan negatif dengan kemiskinan. Penurunan kemiskinan paling jelas terjadi pada peningkatan lama sekolah dari rentang rendah menuju menengah, yaitu dari sekitar 2 sampai 4 tahun menuju 7 sampai 8 tahun. Setelah itu, kurva tetap menurun tetapi dengan laju yang lebih kecil hingga mencapai sekitar 5% sampai 6% pada lama sekolah tertinggi. Pola tersebut mengindikasikan adanya *diminishing return*, yaitu tambahan peningkatan

pendidikan tetap berkaitan dengan penurunan kemiskinan, tetapi besarnya pengaruh semakin berkurang pada tingkat pendidikan yang lebih tinggi.

Hasil pemodelan *Bayesian* GAM menunjukkan bahwa log PDRB regional, angka harapan hidup, dan rata-rata lama sekolah memiliki hubungan negatif dengan persentase penduduk miskin. Namun, hubungan tersebut tidak bersifat linier konstan, melainkan menunjukkan pola nonlinier yang ditandai oleh penurunan kemiskinan yang relatif tajam pada tingkat awal prediktor dan kemudian melandai pada nilai yang lebih tinggi. Hal ini mengindikasikan bahwa perubahan kondisi ekonomi, kesehatan, dan pendidikan memberikan dampak yang berbeda pada setiap tingkat pembangunan wilayah.

Hal ini menunjukkan bahwa hubungan antara faktor-faktor sosial ekonomi dan kemiskinan tidak dapat sepenuhnya direpresentasikan oleh model linier sederhana. Dengan menggunakan fungsi *smooth*, *Bayesian* GAM mampu menangkap perubahan pengaruh prediktor pada berbagai rentang nilai sehingga memberikan gambaran yang lebih realistis mengenai dinamika kemiskinan antarwilayah.

Dari sisi kebijakan, hasil penelitian mengindikasikan bahwa upaya pengurangan kemiskinan akan lebih efektif apabila difokuskan pada daerah dengan tingkat pembangunan ekonomi, kesehatan, dan pendidikan yang masih rendah. Pada daerah tersebut, peningkatan indikator-indikator pembangunan cenderung menghasilkan penurunan kemiskinan yang lebih besar dibandingkan daerah yang sudah relatif maju. Oleh karena itu, pendekatan kebijakan yang mempertimbangkan kondisi awal masing-masing wilayah berpotensi lebih efektif dibandingkan kebijakan yang diterapkan secara seragam pada seluruh daerah.

4. KESIMPULAN DAN SARAN

Penelitian mengaplikasikan *Bayesian* GAM berbasis *P-spline* dengan distribusi Gamma dan fungsi penghubung log untuk memodelkan persentase penduduk miskin pada tingkat kabupaten/kota di Indonesia. Hasil eksplorasi data mengindikasikan bahwa persentase penduduk miskin memiliki distribusi positif, menceng ke kanan, serta menunjukkan variasi yang cukup substansial antarwilayah. Karakteristik tersebut menjadikan distribusi Gamma lebih sesuai dibandingkan distribusi Normal. Di samping itu, PDRB regional menunjukkan sebaran yang sangat menceng ke kanan, sehingga transformasi logaritma diperlukan sebelum pemodelan.

Hasil pemodelan menunjukkan bahwa *Bayesian* GAM menghasilkan estimasi yang konvergen, sebagaimana terindikasi dari nilai $\hat{R}$ yang berkisar antara 0,9997 hingga 1,0045. *Posterior predictive check* menginformasi bahwa model mampu mereproduksi distribusi data observasi dengan tingkat kesesuaian yang baik. Nilai *Bayesian R-squared* sebesar 0,624 dengan interval kredibel 95% antara 0,547 dan 0,676 mengindikasikan bahwa model mampu menjelaskan sekitar 62,4% variasi persentase penduduk miskin berdasarkan log PDRB regional, angka harapan hidup, dan rata-rata lama sekolah.

Secara substantif, ketiga prediktor memiliki hubungan negatif dan nonlinier terhadap kemiskinan. Peningkatan PDRB regional, angka harapan hidup, dan rata-rata lama sekolah berasosiasi dengan penurunan persentase penduduk miskin, namun efek marginalnya cenderung lebih besar pada wilayah dengan kondisi awal yang masih rendah dan melandai pada wilayah yang lebih maju. Hal ini mengindikasikan bahwa pendekatan linier sederhana berpotensi menyederhanakan hubungan sosial-ekonomi yang pada kenyataannya bervariasi di sepanjang rentang data.

Berdasarkan hal tersebut, penelitian selanjutnya disarankan untuk mempertimbangkan penambahan variabel lain seperti tingkat pengangguran, ketimpangan pendapatan, infrastruktur, akses layanan dasar, bantuan sosial, dan indikator digital, guna menangkap variasi kemiskinan yang belum dijelaskan oleh model secara lebih komprehensif. Selain itu, penggunaan data panel dan pengembangan model dengan komponen spasial dapat menjadi pertimbangan lanjutan, mengingat kemiskinan antarwilayah berpotensi memiliki ketergantungan geografis (*spatial dependence*). Dari perspektif kebijakan, hasil penelitian ini mengindikasikan bahwa intervensi di bidang ekonomi, kesehatan, dan pendidikan sebaiknya

mempertimbangkan kondisi awal masing-masing daerah, sehingga wilayah yang masih tertinggal dapat memperoleh prioritas intervensi yang lebih tepat sasaran.

DAFTAR PUSTAKA

- [1] Alim, S., & Harsono, I. (2025). Pengaruh pertumbuhan ekonomi, pendidikan dan kesehatan terhadap kemiskinan di Provinsi Nusa Tenggara Barat tahun 2015–2024. *Jurnal Syntax Imperatif: Jurnal Ilmu Sosial dan Pendidikan*, 6(3). <https://doi.org/10.54543/syntaximperatif.v6i3.701>
- [2] Badan Pusat Statistik. (2024a). *Persentase penduduk miskin Maret 2024 turun menjadi 9,03 persen*. <https://www.bps.go.id/id/pressrelease/2024/07/01/2370/persentase-penduduk-miskin-maret-2024-turun-menjadi-9-03-persen-.html>
- [3] Badan Pusat Statistik. (2024b). *Data dan informasi kemiskinan kabupaten/kota tahun 2024*. <https://www.bps.go.id/id/publication/2024/11/29/d2848c3990f081182125a416/data-dan-informasi-kemiskinan-kabupaten--kota-tahun-2024.html>
- [4] Bürkner, P.-C. (2017). *brms: An R package for Bayesian multilevel models using Stan*. *Journal of Statistical Software*, 80(1), 1–28. <https://doi.org/10.18637/jss.v080.i01>
- [5] Eilers, P. H. C., & Marx, B. D. (1996). Flexible smoothing with B-splines and penalties. *Statistical Science*, 11(2), 89–121. <https://doi.org/10.1214/ss/1038425655>
- [6] Fauzan, E. N., Istikomah, N., Kurniawati, S., & Machmud, A. (2026). The role of human capital based on education and health against poverty in 34 provinces in Indonesia. *Dinasti International Journal of Education Management and Social Science*, 7(3). <https://doi.org/10.38035/dijemss.v7i3.5992>
- [7] Fernando, E., & Samsuddin, M. A. (2025). Analisis pengaruh tingkat kesehatan dan tingkat pendidikan terhadap tingkat kemiskinan di Indonesia tahun 2017–2024. *Jurnal Ilmu Ekonomi dan Bisnis*, 2(2), 54–59. <https://doi.org/10.70134/jukoni.v2i2.533>
- [8] Gelman, A., Goodrich, B., Gabry, J., & Vehtari, A. (2019). *R-squared for Bayesian regression models*. *The American Statistician*, 73(3), 307–309. <https://doi.org/10.1080/00031305.2018.1549100>
- [9] Gelman, A., Meng, X.-L., & Stern, H. (1996). Posterior predictive assessment of model fitness via realized discrepancies. *Statistica Sinica*, 6(4), 733–807.
- [10] Hastie, T. J., & Tibshirani, R. (1986). Generalized additive models. *Statistical Science*, 1(3), 297–310.
- [11] Hoffman, M. D., & Gelman, A. (2014). The No-U-Turn sampler: Adaptively setting path lengths in Hamiltonian Monte Carlo. *Journal of Machine Learning Research*, 15(47), 1593–1623.
- [12] Riskiani, D., Yasin, M., & Chaidir, T. (2025). Determinants of poverty in Indonesia in 2019–2023: A case study of the ten poorest provinces. *Journal of Economics, Finance and Management Studies*, 8(12). <https://doi.org/10.47191/jefms/v8-i12-25>
- [13] Sarmilah, S., & Amalita, N. (2026). Perbandingan regresi linear dan penalized spline dalam analisis indikator pendidikan di Indonesia tahun 2024. *Imajiner: Jurnal Matematika dan Pendidikan Matematika*, 8(2), 511–517. <https://doi.org/10.26877/imaginer.v8i2.26962>
- [14] Simanjuntak, M. J. L. (2025). Garis kemiskinan di DKI Jakarta: Analisis regresi non-linear dengan GAM. *AKSIOMA: Jurnal Sains, Ekonomi dan Edukasi*, 2(2). <https://doi.org/10.62335/aksioma.v2i2.868>
- [15] Sitorus, Y. F., Muchtar, M., & Sihombing, P. R. (2024). Pengaruh tingkat pendidikan dan tingkat kesehatan terhadap PDRB per kapita di Indonesia. *Journal of Law, Administration, and Social Science*, 4(1). <https://doi.org/10.54957/jolas.v4i1.692>
- [16] United Nations. (2024). *The 17 Goals*. <https://sdgs.un.org/goals>

- [17] Vehtari, A., Gelman, A., Simpson, D., Carpenter, B., & Bürkner, P.-C. (2021). Rank-normalization, folding, and localization: An improved R-hat for assessing convergence of MCMC. *Bayesian Analysis*, 16(2), 667–718. <https://doi.org/10.1214/20-BA1221>
- [18] Wood, S. N. (2017). *Generalized additive models: An introduction with R* (2nd ed.). CRC Press.
- [19] World Bank. (2024). *Poverty & Equity Brief: Indonesia*. World Bank Group.