



Perbandingan *Ant Colony Optimization* dan *Simulated Annealing* pada Seleksi Fitur dan *Hyperparameter Tuning* untuk Prediksi Readmisi Diabetes

Helmi Falah^{1*} , Rafi Adabhi Sunarya¹ , Qindy Naura¹ , Sabitala Dinika¹ , Muhammad Sabda Agama¹ , Sachnaz Desta Oktarina^{1*} , Bagus Sartono¹ , Akbar Rizki¹ , Rahma Anisa¹ , Indra Mahib Zuhair Riyanto¹

¹ Study Program of Statistics and Data Science, IPB University, Indonesia

* Corresponding Author. E-mail: sachnazdes@apps.ipb.ac.id

ARTICLE INFO

Article History:

Received: xx-Nov. 2020

Revised: xx-Nov. 2020

Accepted: xx-Dec. 2020

Keywords:

Ant Colony Optimization, diabetes readmission, feature selection, Random Forest, Simulated Annealing.

ABSTRACT

Readmission pada pasien diabetes merupakan permasalahan penting dalam pelayanan kesehatan karena berkontribusi terhadap peningkatan biaya perawatan dan beban rumah sakit. Dalam *machine learning*, *Ant Colony Optimization* (ACO) dan *Simulated Annealing* (SA) merupakan algoritma metaheuristik yang banyak digunakan untuk menyelesaikan permasalahan optimasi, termasuk seleksi fitur dan penentuan *hyperparameter* model klasifikasi. Penelitian ini bertujuan membandingkan efektivitas SA dan ACO dalam meningkatkan kinerja *Random Forest* (RF) melalui seleksi fitur dan optimasi *hyperparameter* pada prediksi *readmission* pasien diabetes. Data yang digunakan adalah Diabetes 130-US Hospitals for Years 1999–2008 dari UCI *Machine learning* Repository. Setelah proses pra-proses data, transformasi *One-Hot Encoding* menghasilkan 191 fitur yang digunakan dalam proses optimasi. Seleksi fitur dilakukan menggunakan SA dan ACO dengan fungsi objektif *composite* yang menggabungkan ROC-AUC dan tingkat reduksi fitur, dilanjutkan dengan optimasi *hyperparameter* RF. Hasil penelitian menunjukkan bahwa SA menghasilkan reduksi fitur sebesar 84,82% dan *composite score* sebesar 0,614, sedangkan ACO menghasilkan reduksi fitur sebesar 91,10% dan *composite score* sebesar 0,623. Pada data uji, model RF *baseline* memperoleh ROC-AUC sebesar 0,647 dengan 191 fitur, RF-SA memperoleh ROC-AUC sebesar 0,588 dengan 29 fitur, dan RF-ACO memperoleh ROC-AUC sebesar 0,591 dengan 17 fitur. Berdasarkan metrik utama penelitian, yaitu *composite score*, RF-ACO memberikan kinerja terbaik karena mampu mempertahankan performa prediksi yang kompetitif dengan jumlah fitur yang jauh lebih sedikit. Dengan demikian, ACO lebih efektif dibandingkan SA dalam menghasilkan model RF yang efisien untuk prediksi *readmission* pasien diabetes pada data rekam medis berdimensi tinggi.

Hospital readmission among diabetes patients is an important healthcare issue because it contributes to increased treatment costs and hospital burden. Ant Colony Optimization (ACO) and Simulated Annealing (SA) are metaheuristic algorithms commonly used for optimization tasks, including feature selection and hyperparameter tuning. This study compares the effectiveness of SA and ACO in improving Random Forest (RF) performance for diabetes readmission prediction through feature selection and hyperparameter optimization. The dataset used was Diabetes 130-US Hospitals for Years 1999–2008 from the UCI Machine learning Repository. After preprocessing, One-Hot Encoding generated 191 features for optimization. Feature selection was performed using SA and ACO with a composite objective function combining ROC-AUC and feature reduction rate, followed by RF hyperparameter optimization. The results showed that SA achieved a feature reduction rate of 84.82% with a composite score of 0.614, while ACO achieved a feature reduction rate of 91.10% with a composite score of 0.623. On the test set, the baseline RF model obtained a ROC-AUC of 0.647 using 191 features, RF-SA achieved a ROC-AUC of 0.588 using 29 features, and RF-ACO achieved a ROC-AUC of 0.591 using 17 features. Based on the primary evaluation metric, namely the composite score, RF-ACO delivered the best overall performance by maintaining competitive predictive capability while using substantially fewer features. Therefore, ACO was more effective than SA in producing an efficient RF model for diabetes readmission prediction on high-dimensional electronic health record data.



Scan me

This is an open access article under the [CC-BY-SA](https://creativecommons.org/licenses/by-sa/4.0/) license



How to Cite:

Falah, H., Sunarya, R. A., Naura, Q., Dinika, S., Agama, M. S., Oktarina, S. D., Sartono, B., Rizki, A., Anisa, R., & Riyanto, M. Z. (2020). Perbandingan *ant colony optimization* dan *simulated annealing* pada seleksi fitur dan *hyperparameter tuning* untuk prediksi readmisi diabetes. *Pythagoras: Jurnal Pendidikan Matematika*, 15(1), 1-5. <https://doi.org/10.21831/pg.v13ixxxxx>

 <https://doi.org/10.21831/pg.v13ixxxxx>

PENDAHULUAN

Kemampuan mengklasifikasikan data secara akurat menjadi salah satu fondasi penting dalam pengambilan keputusan berbasis data. Kebutuhan tersebut muncul di berbagai bidang mulai dari deteksi penipuan finansial hingga diagnosis penyakit. Di bidang kesehatan, kebutuhan akan model klasifikasi yang andal semakin meningkat seiring berkembangnya penggunaan rekam medis elektronik yang menghasilkan data pasien dalam jumlah besar. Salah satu algoritma yang banyak digunakan untuk mengolah data tersebut adalah RF. Algoritma ini bekerja dengan menggabungkan prediksi dari banyak pohon keputusan sehingga mampu menghasilkan performa yang stabil. Kemampuannya dalam menangani data yang kompleks membuat RF banyak digunakan dalam berbagai penelitian prediksi klinis.

Performa RF tetap dipengaruhi oleh karakteristik data yang digunakan. Permasalahan ini sering muncul ketika jumlah fitur yang dianalisis menjadi sangat banyak. Pada data kesehatan, kondisi tersebut umumnya terjadi karena banyaknya variabel kategorik yang ditransformasikan melalui *one-hot encoding*. Proses ini dapat menghasilkan ratusan fitur baru dari sejumlah variabel awal. Tidak semua fitur yang terbentuk memiliki kontribusi penting terhadap proses klasifikasi. Sebagian fitur bersifat redundan dan sebagian lainnya kurang relevan terhadap target prediksi. Keberadaan fitur-fitur tersebut dapat meningkatkan kompleksitas model dan memperbesar biaya komputasi. Penerapan seleksi fitur berbasis *Information Gain* yang dikombinasikan dengan strategi penyeimbangan data dilaporkan mampu meningkatkan performa RF pada delapan dataset dengan karakteristik yang berbeda (Prasetyowati et al., 2022). Temuan tersebut menunjukkan bahwa pemilihan fitur masih menjadi langkah penting untuk memperoleh model yang lebih efisien tanpa mengorbankan performa klasifikasi.

Selain ditentukan oleh fitur yang digunakan, performa RF juga dipengaruhi oleh konfigurasi *hyperparameter* model. Parameter yang umum digunakan antara lain jumlah pohon (*n_estimators*), kedalaman maksimum pohon (*max_depth*), jumlah sampel minimum untuk melakukan split (*min_samples_split*), jumlah sampel minimum pada setiap leaf (*min_samples_leaf*), dan jumlah fitur yang dipertimbangkan pada setiap split (*max_features*). Nilai yang berbeda pada parameter tersebut dapat menghasilkan performa model yang berbeda pula. Dalam praktiknya, proses penentuan *hyperparameter* sering dilakukan secara manual atau menggunakan *grid search*. Pendekatan tersebut menjadi kurang efisien ketika ruang pencarian semakin besar karena jumlah kombinasi yang harus dievaluasi terus bertambah. Oleh karena itu, diperlukan pendekatan yang mampu menentukan kombinasi fitur dan *hyperparameter* secara lebih efektif sehingga model yang dihasilkan memiliki performa yang baik dan tetap efisien dari sisi komputasi.

Permasalahan optimasi seperti ini banyak diselesaikan menggunakan algoritma metaheuristik. ACO merupakan salah satu metode yang terinspirasi dari perilaku koloni semut dalam menemukan jalur terbaik menuju sumber makanan. Proses pencarian dilakukan melalui mekanisme jejak feromon yang merepresentasikan kualitas suatu solusi. Berbagai penelitian menunjukkan bahwa ACO mampu memilih fitur yang relevan sekaligus menentukan konfigurasi parameter yang baik pada data dengan jumlah fitur yang besar. Pendekatan berbasis ACO dilaporkan menghasilkan rata-rata akurasi sebesar 98,91% pada delapan dataset kanker dengan jumlah fitur yang jauh lebih sedikit dibandingkan data awal (Saraç & Özel, 2014). Hasil tersebut menunjukkan bahwa ACO mampu mengurangi dimensi data tanpa menurunkan performa klasifikasi secara signifikan. Metode lain yang juga banyak digunakan adalah SA. Berbeda dengan ACO, metode ini memanfaatkan mekanisme probabilistik dalam proses pencarian solusi. Karakteristik tersebut memungkinkan SA menjelajahi ruang solusi yang lebih luas dan mengurangi risiko terjebak pada solusi lokal. Integrasi seleksi fitur dan *hyperparameter tuning* menggunakan SA dilaporkan mampu meningkatkan performa RF secara konsisten pada berbagai dataset termasuk beberapa kasus yang berkaitan dengan diagnostik medis (Balasubramanian et al., 2025).

Prediksi *readmission* pasien diabetes merupakan salah satu kasus yang memiliki karakteristik sesuai dengan permasalahan tersebut. Diabetes mellitus adalah penyakit kronis yang jumlah penderitanya terus meningkat di

seluruh dunia. Pada tahun 2024, sekitar 589 juta penduduk dewasa berusia 20–79 tahun hidup dengan diabetes dan jumlah tersebut diproyeksikan meningkat menjadi 853 juta orang pada tahun 2050 (Genitsaridi et al., 2025). Peningkatan prevalensi diabetes turut meningkatkan risiko rawat inap berulang atau *hospital readmission* akibat komplikasi penyakit. Dampaknya tidak hanya terlihat pada meningkatnya biaya pelayanan kesehatan tetapi juga pada bertambahnya beban rumah sakit dan menurunnya kualitas hidup pasien. Oleh karena itu, kemampuan memprediksi *readmission* menjadi penting untuk mendukung pengambilan keputusan klinis yang lebih baik.

Dari sudut pandang *machine learning*, kasus *readmission* diabetes juga menarik karena dataset yang digunakan umumnya memuat banyak variabel kategorik sehingga menghasilkan jumlah fitur yang cukup besar setelah proses *one-hot encoding*. Kondisi ini menuntut algoritma yang mampu menangani data berdimensi tinggi serta hubungan nonlinier antarvariabel. RF merupakan salah satu metode *ensemble* berbasis pohon keputusan yang banyak digunakan dalam prediksi *readmission* diabetes karena mampu menangani data klinis yang kompleks dan heterogen. Pada studi terbaru menggunakan dataset Diabetes 130-US Hospitals, RF mencapai nilai ROC-AUC sebesar 0,650, yang relatif sebanding dengan *Logistic Regression* (0,657), *LightGBM* (0,660), dan *XGBoost* (0,664) pada skema evaluasi *nested cross-validation* yang ketat (Salim & Ibrahim, 2026).

Penelitian pada kasus *readmission* diabetes masih didominasi oleh penggunaan model klasifikasi standar. Kajian yang mengintegrasikan seleksi fitur dan *hyperparameter tuning* menggunakan algoritma metaheuristik masih relatif terbatas. Sementara itu, penelitian mengenai SA dan ACO umumnya dilakukan pada dataset yang berbeda seperti data diagnostik umum dan klasifikasi kanker. Akibatnya, belum ada gambaran yang jelas mengenai perbandingan kinerja kedua metode tersebut pada kasus *readmission* diabetes. Sebagian besar penelitian terdahulu juga lebih berfokus pada peningkatan akurasi atau ROC-AUC. Efisiensi jumlah fitur yang digunakan masih jarang menjadi perhatian utama, padahal model yang lebih ringkas cenderung lebih mudah diinterpretasikan dan lebih praktis diterapkan di lingkungan rumah sakit.

Penelitian ini menerapkan ACO dan SA untuk melakukan seleksi fitur serta *hyperparameter tuning* pada model RF dalam prediksi *readmission* pasien diabetes. Kedua metode digunakan untuk mencari kombinasi fitur dan parameter yang memberikan performa terbaik. Evaluasi dilakukan dengan mempertimbangkan kemampuan klasifikasi dan efisiensi jumlah fitur yang digunakan. Penelitian ini bertujuan membandingkan efektivitas ACO dan SA dalam meningkatkan kinerja pada prediksi *readmission* pasien diabetes.

METODE

Penelitian ini merupakan penelitian kuantitatif komparatif berbasis komputasi yang bertujuan membandingkan efektivitas dua algoritma optimasi metaheuristik, yaitu SA dan ACO. Kedua algoritma diterapkan untuk seleksi fitur dan optimasi *hyperparameter tuning* pada model klasifikasi RF, yang meliputi penyesuaian jumlah pohon (*n_estimators*), kedalaman maksimum pohon (*max_depth*), sampel minimum untuk pemecahan simpul (*min_samples_split*), sampel minimum pada daun (*min_samples_leaf*), serta jumlah fitur maksimum yang dipertimbangkan (*max_features*).

Variabel dalam Penelitian

Penelitian ini menggunakan dataset *Diabetes 130-US Hospitals for Years 1999–2008* yang diperoleh dari UCI Machine learning Repository. Dataset memiliki 101.766 observasi dengan 50 kolom, yang terdiri atas 47 variabel input (prediktor), dua kolom identitas pasien, dan satu variabel target, yaitu status *readmission* pasien. Variabel *readmitted* merepresentasikan waktu pasien kembali menjalani rawat inap setelah keluar dari perawatan sebelumnya dan pada dataset asli terdiri atas tiga kategori, yaitu kategori <30 apabila pasien dirawat kembali dalam waktu kurang dari 30 hari, kategori >30 apabila pasien dirawat kembali setelah lebih dari 30 hari, dan kategori No apabila tidak terdapat catatan rawat inap kembali. Dataset mencakup informasi demografis, riwayat perawatan, pemeriksaan laboratorium, diagnosis, dan pengobatan pasien dari 130 rumah sakit di Amerika Serikat selama periode 1999–2008, dengan tipe data berupa variabel numerik dan kategorik. Informasi lengkap mengenai variabel dan karakteristik dataset dapat diakses melalui dokumentasi resmi UCI Machine learning Repository pada tautan <https://archive.ics.uci.edu/dataset/296/diabetes+130-us+hospitals+for+years+1999-2008>.

Simulated Annealing (SA)

Secara konseptual, algoritma SA diadopsi dari analogi proses termodinamika pendinginan logam secara perlahan untuk mencapai konfigurasi energi minimum yang stabil (Cherian et al., 2024). Pada algoritma ini, temperatur (T) berperan sebagai parameter yang mengontrol keseimbangan eksplorasi dan eksploitasi ruang solusi. Proses optimasi diawali dengan inialisasi solusi awal (S_0), temperatur awal (T_0), dan laju pendinginan (γ) stabil (Cherian et al., 2024). Pada setiap iterasi, kandidat solusi baru (S') dibangkitkan melalui gangguan kecil pada solusi saat ini (S), kemudian dihitung perubahan nilai fungsi objektif sebagaimana ditunjukkan pada Persamaan 1. Mekanisme ini merupakan karakteristik utama SA yang melakukan pencarian solusi melalui perpindahan antar konfigurasi yang berdekatan dalam ruang pencarian (Syaiful et al., 2021).

$$\Delta E = E(S') - E(S) \quad (1)$$

dengan $E(S')$ dan $E(S)$ masing-masing menyatakan nilai fungsi objektif atau tingkat kebaikan (*fitness value*) dari kandidat solusi baru dan solusi saat ini yang merepresentasikan kualitas dari kombinasi fitur atau *hyperparameter* yang sedang dievaluasi. Jika $\Delta E > 0$, solusi baru diterima secara langsung. Sebaliknya, jika $\Delta E \leq 0$, solusi diterima dengan probabilitas pada Persamaan 2 (Cherian et al., 2024):

$$P_{accept} = e^{-\frac{\Delta E}{T}} \quad (2)$$

P_{accept} merupakan probabilitas penerimaan solusi dan T adalah temperatur pada iterasi tersebut. P_{accept} berperan sebagai sebagai batas keputusan untuk menentukan apakah kandidat solusi yang lebih buruk akan diterima atau tidak. Proses dilakukan dengan membangkitkan bilangan acak r dari interval $[0,1]$ kemudian S' akan diterima jika $r < P_{accept}$. Mekanisme ini merupakan ciri khas utama algoritma SA yang memungkinkannya terhindar dari *local optimum*, sebab ruang pencarian dapat dieksplorasi lebih luas sebelum konvergen menuju solusi terbaik. Tingkat eksplorasi ini dikendalikan oleh nilai temperatur yang diturunkan secara bertahap menggunakan Persamaan 3:

$$T = \gamma \times T \quad (3)$$

γ merupakan laju pendinginan dengan ruang himpunan nilai $\gamma \in (0,1)$. Mekanisme penerimaan solusi dan proses pendinginan tersebut menjadi dasar implementasi SA pada penelitian ini. Algoritma digunakan pada dua tahap Optimasi, yaitu seleksi fitur dan Optimasi *hyperparameter* RF. Meskipun keduanya mengikuti prinsip penerimaan solusi dan penurunan temperatur yang sama sebagaimana dijelaskan pada Persamaan 1-3, representasi solusi dan fungsi objektif yang digunakan berbeda sesuai dengan tujuan Optimasi pada masing-masing tahap. Implementasi SA untuk seleksi fitur dan Optimasi *hyperparameter* disajikan pada Algoritma 1 dan Algoritma 2.

Input : Data pelatihan, suhu awal T_0 , laju pendinginan γ ,
suhu minimum T_{min} , maksimum iterasi

Output : Subset fitur terbaik s^*

Bangkitkan solusi awal s

Hitung *fitness* $f(s)$ menggunakan Persamaan 6

Tetapkan $s^* = s$

while ($T > T_{min}$ dan iterasi $<$ MaksIterasi)

 Bangkitkan solusi tetangga s'

 (*add, remove, atau swap* fitur)

 Hitung *fitness* $f(s')$

 Hitung ΔE menggunakan Persamaan 1

 if ($\Delta E > 0$)

 Terima solusi s'

 else

 Bangkitkan bilangan acak $r \in [0,1]$

```

Hitung P_accept menggunakan Persamaan 2
if (r < P_accept)
    Terima solusi s'
end if
end if
Perbarui solusi terbaik s* jika diperlukan
Perbarui temperatur menggunakan Persamaan 3
end while
Kembalikan s*
    
```

Algoritma 1. SA untuk seleksi fitur

Pada tahap seleksi fitur, solusi direpresentasikan sebagai subset fitur hasil proses *encoding*. Kualitas setiap solusi dievaluasi menggunakan fungsi *fitness composite* pada Persamaan 6 yang menggabungkan performa prediksi dan tingkat reduksi fitur. Subset fitur dengan nilai fitness terbaik kemudian digunakan sebagai masukan pada tahap Optimasi *hyperparameter*.

```

Input  : Data pelatihan, subset fitur terpilih, suhu awal T0,
        laju pendinginan γ, suhu minimum Tmin, maksimum iterasi
Output : Kombinasi hyperparameter terbaik θ*

Bangkitkan hyperparameter awal θ
Hitung ROC-AUC(θ)
Tetapkan θ* = θ

while (T > T_min dan iterasi < Maks_iterasi)
    Bangkitkan solusi tetangga θ'
    (ubah satu hyperparameter)
    Hitung ROC-AUC (θ')
    Hitung ΔE menggunakan Persamaan 1
    if (ΔE > 0)
        Terima solusi θ'
    else
        Bangkitkan bilangan acak r ∈ [0,1]
        Hitung P_accept menggunakan Persamaan 2
        if (r < P_accept)
            Terima solusi θ'
        end if
    end if
    Perbarui solusi terbaik θ* jika diperlukan
    Perbarui temperatur menggunakan Persamaan 3
end while
Kembalikan θ*
    
```

Algoritma 2. SA untuk Optimasi Hyperparameter

Solusi pada tahap Optimasi hyperparameter direpresentasikan sebagai kombinasi nilai *hyperparameter* RF. Evaluasi kualitas solusi dilakukan menggunakan nilai ROC-AUC pada data validasi karena subset fitur telah ditetapkan pada tahap sebelumnya. Hasil Optimasi ini menghasilkan kombinasi *hyperparameter* terbaik yang selanjutnya digunakan dalam pembentukan model RF final.

Ant Colony Optimization (ACO)

ACO merupakan algoritma optimasi metaheuristik berbasis populasi yang terinspirasi dari perilaku koloni semut dalam menemukan jalur terpendek menuju sumber makanan (Ashokkumar et al., 2025). Setiap

semut bertindak sebagai agen stokastik independen yang membangun solusi berupa subset fitur secara inkremental berdasarkan informasi feromon (τ) dan informasi heuristik (η). Probabilitas semut ke- k memilih fitur ke- j pada iterasi ke- t dinyatakan pada Persamaan 4 (Wardana et al., 2025):

$$P_j^k(t) = \frac{[\tau_j(t)]^\alpha [\eta_j(t)]^\beta}{\sum_{l \in N^k} [\tau_l(t)]^\alpha [\eta_l(t)]^\beta} \quad (4)$$

dengan $\tau_j(t)$ merupakan nilai feromon pada fitur ke- j pada iterasi ke- t , $\eta_j(t)$ merupakan nilai heuristik transisi i ke- j , α merupakan bobot pengaruh feromon, β merupakan bobot pengaruh heuristik, dan N_j^k merupakan himpunan komponen layak yang dapat dipilih oleh semut ke- k . Semakin besar nilai feromon dan heuristik suatu fitur, semakin besar peluang fitur tersebut terpilih. Setelah seluruh subset fitur dievaluasi, nilai feromon diperbarui berdasarkan performa klasifikasi yang dihasilkan. Proses pembaruan feromon dilakukan menggunakan Persamaan 5, yang diadaptasi dari (Wardana et al., 2025) dengan menyesuaikan parameter $\rho \in (0,1)$ sebagai laju penguapan standar komputasi:

$$\tau_j(t) = (1 - \rho)\tau_j(t - 1) + \sum_{k=1}^n \Delta\tau_j^k(t) \quad (5)$$

$\Delta\tau_j^k(t)$ merupakan tambahan feromon yang diberikan oleh semut ke- k pada fitur ke- j , dan n adalah jumlah total semut dalam koloni. Semakin baik performa subset fitur, semakin besar peluangnya untuk dipilih pada iterasi berikutnya. Semakin baik performa subset fitur, semakin besar peluangnya untuk dipilih pada iterasi berikutnya. Mekanisme pembentukan solusi, evaluasi *fitness*, dan pembaruan feromon tersebut menjadi dasar implementasi ACO pada penelitian ini. Algoritma digunakan pada dua tahap Optimasi, yaitu seleksi fitur dan Optimasi *hyperparameter* RF. Meskipun keduanya mengikuti prinsip konstruksi solusi dan pembaruan feromon yang sama sebagaimana dijelaskan pada Persamaan (4) dan (5), representasi solusi dan fungsi objektif yang digunakan berbeda sesuai dengan tujuan Optimasi pada masing-masing tahap. Implementasi ACO untuk seleksi fitur dan Optimasi *hyperparameter* disajikan pada Algoritma 3 dan Algoritma 4.

Input : Data pelatihan, fitur kandidat, jumlah semut, maksimum iterasi,
 α , β , ρ , τ min, τ max, top-k semut terbaik, dan fungsi *fitness* $f(s)$

Output : Subset fitur terbaik s^*

Inisialisasi nilai feromon τ untuk seluruh fitur

Tetapkan solusi terbaik awal s^*

while iterasi < maksimum iterasi dan kriteria penghentian belum terpenuhi *do*

for setiap semut k *do*

 Bangkitkan subset fitur s_k secara bertahap

 berdasarkan probabilitas pemilihan fitur pada Persamaan 4

 Evaluasi subset fitur s_k menggunakan fungsi *fitness composite*

 pada Persamaan 6

end for

 Pilih top-k semut dengan nilai *fitness* terbaik

 Lakukan penguapan feromon menggunakan parameter ρ

 Perbarui nilai feromon berdasarkan kualitas subset fitur menggunakan Persamaan 5

 Perbarui solusi terbaik s^* jika ditemukan subset fitur dengan nilai *fitness* yang lebih tinggi

end while

Kembalikan s^*

Algoritma 3. ACO untuk seleksi fitur

Pada tahap seleksi fitur, setiap semut membangun kandidat subset fitur secara bertahap berdasarkan kombinasi informasi feromon dan heuristik. Kualitas setiap subset fitur dievaluasi menggunakan fungsi fitness composite pada Persamaan (6). Subset fitur dengan nilai fitness terbaik selanjutnya digunakan sebagai masukan pada tahap Optimasi hyperparameter.

```

Input : Data pelatihan, subset fitur terpilih, ruang hyperparameter,
        jumlah semut, maksimum iterasi,  $\alpha$ ,  $\beta$ ,  $\rho$ , dan top-k semut terbaik
Output : Kombinasi hyperparameter terbaik  $\theta^*$ 

Inisialisasi nilai feromon  $\tau$  untuk setiap pilihan hyperparameter
Tetapkan solusi terbaik awal  $\theta^*$ 

while iterasi < maksimum iterasi dan kriteria penghentian belum terpenuhi do

    for setiap semut k do
        Bangkitkan kombinasi hyperparameter  $\theta_k$  berdasarkan probabilitas pemilihan pada Persamaan 4
        Latih model RF menggunakan  $\theta_k$ 
        pada subset fitur terpilih
        Evaluasi  $\theta_k$  menggunakan nilai ROC-AUC
        pada data validasi
    end for
    Pilih top-k semut dengan nilai ROC-AUC terbaik
    Lakukan penguapan feromon menggunakan parameter  $\rho$ 
    Perbarui nilai feromon berdasarkan kualitas kombinasi hyperparameter menggunakan Persamaan 5
    Perbarui solusi terbaik  $\theta^*$  jika ditemukan kombinasi hyperparameter
    dengan nilai ROC-AUC yang lebih tinggi
end while

Kembalikan  $\theta^*$ 
    
```

Algoritma 4. ACO untuk Optimasi *Hyperparameter*

Berbeda dengan tahap seleksi fitur, solusi pada tahap Optimasi hyperparameter direpresentasikan sebagai kombinasi nilai hyperparameter RF. Setiap semut membangun kombinasi hyperparameter yang kemudian dievaluasi menggunakan nilai ROC-AUC pada data validasi. Hasil Optimasi menghasilkan kombinasi hyperparameter terbaik yang digunakan dalam pembentukan model RF final.

Fungsi *Fitness Composite*

Optimasi pada data rekam medis melibatkan dua tujuan yang harus diselesaikan secara simultan yaitu memaksimalkan performa prediksi klinis dan meminimalkan jumlah fitur yang digunakan. Oleh karena itu, digunakan fungsi objektif berbentuk *composite* berbasis maksimasi (*maximization*) yang menggabungkan kedua komponen tersebut. Fungsi *fitness* ini diadaptasi dari pendekatan *wrapper feature selection* yang mengombinasikan performa klasifikasi dan ukuran subset fitur dalam satu fungsi objektif (Mafarja & Mirjalili, 2018). Solusi optimal diperoleh dengan memaksimalkan fungsi *fitness* seperti pada Persamaan 6:

$$s^* = \arg \max_{s \in \Omega} f(s); f(s) = w \cdot \text{ROC-AUC} + (1 - w) \left(1 - \frac{N_{\text{terpilih}}}{N_{\text{total}}} \right) \quad (6)$$

di mana s merepresentasikan kandidat solusi yang terdiri atas kombinasi subset fitur dan *hyperparameter*, sedangkan Ω adalah himpunan seluruh solusi yang mungkin. Komponen ROC-AUC mengukur kemampuan model dalam membedakan pasien yang mengalami dan tidak mengalami kejadian klinis pada berbagai nilai *threshold*, sehingga memberikan evaluasi performa yang lebih komprehensif dibandingkan akurasi tunggal. Selain itu, ROC-AUC relatif lebih *robust* terhadap ketidakseimbangan kelas karena mempertimbangkan *trade-*

off antara *sensitivity* dan *specificity* secara simultan. Sementara itu, komponen $\left(1 - \frac{N_{\text{terpilih}}}{N_{\text{total}}}\right)$ merepresentasikan tingkat reduksi fitur terhadap total fitur kandidat. Nilai w ditetapkan sebesar 0,90 agar performa prediksi tetap menjadi komponen dominan, mengingat konteks prediksi klinis menuntut model yang akurat untuk mendukung diagnosis dini dan pengambilan keputusan medis. Pendekatan pemberian bobot yang lebih besar pada performa klasifikasi dibandingkan ukuran subset fitur juga sejalan dengan penelitian *feature selection* berbasis metaheuristik yang memprioritaskan kualitas prediksi sebagai tujuan utama Optimasi (Mafarja & Mirjalili, 2018). Sementara itu, bobot 0,10 pada komponen reduksi fitur mendorong algoritma memilih jumlah fitur seminimal mungkin dengan tetap mempertahankan performa prediksi yang optimal (Cherian et al., 2024). Nilai *fitness* yang lebih tinggi menunjukkan solusi yang memiliki kemampuan prediksi lebih baik dengan kompleksitas model yang lebih rendah.

Prosedur Analisis

Pengolahan data dan implementasi seluruh tahapan analisis dalam penelitian dilakukan menggunakan Bahasa pemrograman Python. Berikut langkah-langkah analisis data yang dilakukan:

1. Praproses data mencakup penanganan *missing value*, eliminasi data pasien yang meninggal atau dirujuk ke fasilitas khusus akhir hayat (*hospice*) karena tidak lagi relevan dengan prediksi rawat inap kembali, penghapusan kunjungan duplikat dengan hanya mempertahankan kunjungan pertama per pasien, konversi variabel target *readmitted* menjadi biner ($\text{No} = 0$; <30 hari dan >30 hari = 1), pengelompokan kode diagnosis ICD-9 ke dalam kategori klinis, pengubahan rentang usia menjadi nilai tengahnya, *One-Hot Encoding* untuk fitur kategorik, dan normalisasi dengan *StandardScaler* untuk fitur numerik. Kemudian eksplorasi data juga dilakukan untuk melihat apakah ada informasi yang tumpang tindih (*redundan*) setelah data ditransformasi. Hasil eksplorasi ini divisualisasikan melalui *heatmap* korelasi 25 fitur hasil *encoding* terpilih yang memiliki nilai korelasi paling kuat terhadap target prediksi.
2. Pembagian data secara stratifikasi menjadi data *training* (70%), validasi (10%), dan uji (20%). Data uji tidak digunakan dalam proses apapun hingga evaluasi akhir.
3. Seleksi fitur dilakukan menggunakan algoritma SA dan ACO. Proses seleksi fitur dirumuskan sebagai masalah optimasi kombinatorial, di mana setiap kandidat solusi direpresentasikan sebagai vektor biner $s \in \{0,1\}^D$, dengan D menyatakan jumlah total fitur hasil proses *encoding*. Nilai $s_i = 1$ menunjukkan bahwa fitur ke- i dipilih, sedangkan $s_i = 0$ menunjukkan bahwa fitur tersebut tidak dipilih. Untuk mengendalikan kompleksitas model dan mendorong terbentuknya model yang lebih *parsimonious*, jumlah fitur yang dapat dipilih dibatasi hingga maksimal 30 fitur. Setiap kandidat solusi dievaluasi menggunakan fungsi *fitness composite* $f(s)$ sebagaimana ditunjukkan pada Persamaan 6. Evaluasi *fitness* dilakukan menggunakan model RF dengan konfigurasi awal pada sampel sebanyak 5.000 observasi dari data pelatihan. Penggunaan sampel ini bertujuan mengurangi beban komputasi selama proses Optimasi karena setiap kandidat solusi harus dievaluasi secara berulang. Pada setiap evaluasi *fitness*, data dibagi secara internal menjadi 75% data pelatihan dan 25% data validasi menggunakan *stratified sampling*. Pembagian ini bertujuan menghasilkan estimasi nilai *fitness* yang lebih objektif dengan menghitung komponen ROC-AUC pada data yang tidak digunakan selama proses pelatihan model, sehingga nilai *fitness* yang diperoleh lebih mampu merepresentasikan kemampuan generalisasi model. Proses Optimasi dilakukan hingga diperoleh kombinasi fitur yang menghasilkan nilai *fitness* terbaik.
4. Seleksi fitur menggunakan SA dengan konfigurasi: suhu awal $T_0 = 1$, laju pendinginan $\gamma = 0,95$, maksimum iterasi = 300, jumlah fitur maksimum = 30, suhu minimum = 10^{-3} , dan *early stopping patience* = 30 iterasi.
5. Seleksi fitur menggunakan ACO dengan konfigurasi: jumlah semut = 50, maksimum iterasi = 100, $\alpha = 1$, $\beta = 2$, laju penguapan $\rho = 0,1$, $\tau_{\min} = 0,01$, $\tau_{\max} = 5$, *top-k* semut terbaik = 3, jumlah fitur maksimum = 30, dan *early stopping patience* = 15 iterasi.
6. Optimasi *hyperparameter* model RF dilakukan setelah fitur terpilih diperoleh, menggunakan SA (200 iterasi, $\gamma = 0,95$,) untuk eksperimen RF-SA dan ACO (20 semut, 50 iterasi) untuk eksperimen RF-ACO.


Pada tahap ini fungsi objektif berubah menjadi ROC-AUC murni pada data validasi karena jumlah fitur sudah tetap sehingga komponen *feature reduction* tidak lagi diperlukan.

7. Pelatihan model RF final menggunakan kombinasi fitur terpilih dan *hyperparameter* optimal hasil masing-masing metode dengan parameter *class_weight='balanced'* untuk mengatasi ketidakseimbangan kelas agar hasil prediksi model tidak bias terhadap kelas mayoritas.
8. Pada tahap akhir performa dari masing-masing model yang terbentuk akan dievaluasi dan dibandingkan berdasarkan *composite score* sebagai metrik utama dan dua indikator lainnya yaitu nilai ROC-AUC dan jumlah fitur yang terpilih. Kemudian model terbaik yang terpilih dianalisis lebih lanjut menggunakan metode SHAP (*SHapley Additive exPlanations*) guna memberikan informasi mengenai tingkat kontribusi dan pengaruh fitur terhadap prediksi model.

HASIL PENELITIAN

Dataset awal mencakup 47 variabel prediktor, dengan satu variabel target berupa status *readmission* pasien. Pada tahap praproses data, tiga variabel prediktor, yaitu *weight*, *max_glu_serum*, dan *A1Cresult*, dikeluarkan dari analisis karena memiliki proporsi nilai hilang yang sangat tinggi. Dengan demikian, analisis selanjutnya menggunakan 44 variabel prediktor yang terdiri atas 9 variabel numerik dan 35 variabel kategorik, serta satu variabel target yang telah ditransformasikan menjadi klasifikasi biner. Transformasi variabel kategorik menggunakan *One-Hot Encoding* meningkatkan jumlah fitur dari 44 variabel prediktor menjadi 191 fitur. Setelah proses transformasi, data pelatihan (*training set*) terdiri atas 48.980 observasi dengan 191 fitur, data validasi terdiri atas 6.998 observasi dengan 191 fitur, dan data pengujian (*testing set*) terdiri atas 13.995 observasi dengan 191 fitur.

Hasil praproses menunjukkan bahwa jumlah fitur meningkat lebih dari empat kali lipat dibandingkan jumlah variabel prediktor awal. Kondisi ini mengindikasikan tingginya dimensionalitas data yang berpotensi menyebabkan keberadaan fitur yang kurang informatif maupun redundan. Untuk memperoleh gambaran awal mengenai hubungan antarfitur hasil transformasi, dilakukan analisis korelasi terhadap fitur-fitur hasil *encoding* yang memiliki tingkat kepentingan tertinggi.




Gambar 1. Heatmap korelasi 25 fitur hasil *encoding* terpilih

Gambar 1 menunjukkan heatmap korelasi dari 25 fitur hasil *encoding* yang dipilih berdasarkan nilai korelasi absolut tertinggi terhadap variabel target. Secara umum, sebagian besar pasangan fitur menunjukkan korelasi yang relatif rendah, yang ditunjukkan oleh dominasi warna hijau kebiruan pada matriks korelasi. Kondisi ini mengindikasikan bahwa hubungan linear antarfitur cenderung lemah dan tidak terdapat multikolinearitas yang kuat pada sebagian besar fitur. Namun demikian, beberapa pasangan fitur hasil *One-Hot Encoding* memperlihatkan korelasi negatif yang sangat tinggi, seperti *diabetesMed_Yes* dan *diabetesMed_No*, karena keduanya merepresentasikan kategori yang saling eksklusif dalam variabel yang sama. Selain itu, beberapa fitur yang berkaitan dengan penggunaan obat diabetes juga menunjukkan pola hubungan yang relatif lebih kuat dibandingkan fitur lainnya. Temuan ini menunjukkan bahwa meskipun sebagian besar fitur tidak saling berkorelasi secara kuat, masih terdapat potensi redundansi informasi akibat proses transformasi kategorik.

Kondisi tersebut menunjukkan proses seleksi fitur menjadi penting untuk mengidentifikasi kombinasi fitur yang paling informatif sekaligus mengurangi kompleksitas model. Oleh karena itu, tahap berikutnya dilakukan menggunakan algoritma optimasi SA dan ACO untuk memperoleh subset fitur yang optimal sebelum pembangunan model RF.


Gambar 2 menunjukkan perkembangan nilai *composite score* selama proses optimasi menggunakan SA. Gambar 2a memperlihatkan perubahan nilai *composite score* terbaik dan nilai *composite score* solusi saat ini, sedangkan Gambar 2b menunjukkan penurunan temperatur sepanjang proses optimasi.



Gambar 2. Konvergensi SA: (a) perkembangan *composite score*, (b) penurunan temperatur

Berdasarkan Gambar 2, nilai *composite score* terbaik meningkat secara bertahap hingga mencapai 0,613 pada iterasi ke-136. Seiring penurunan temperatur, peningkatan nilai fitness menjadi semakin kecil hingga algoritma mencapai kondisi konvergen. Hasil akhir menunjukkan bahwa SA mempertahankan 29 fitur dari total 191 fitur kandidat. Hasil akhir menunjukkan bahwa metode SA berhasil menyeleksi 29 fitur dari total 191 fitur kandidat. Hasil tersebut menunjukkan bahwa SA mampu mereduksi jumlah fitur sebesar 84,82% dibandingkan jumlah fitur awal. Fitur-fitur yang terpilih mencakup informasi terkait riwayat rawat inap pasien (*number_inpatient*), karakteristik diagnosis penyakit, sumber dan jenis admisi, serta beberapa variabel terkait pengobatan diabetes. Hal ini mengindikasikan bahwa informasi klinis, riwayat pelayanan kesehatan, dan terapi pengobatan memiliki kontribusi penting dalam memprediksi kejadian *readmission*.

Selain SA, proses seleksi fitur juga dilakukan menggunakan metode ACO. Gambar 3 menunjukkan perkembangan nilai *composite score* dan jumlah fitur pada solusi terbaik selama proses optimasi menggunakan ACO. Gambar 3a menggambarkan perubahan nilai *composite score* pada setiap iterasi, sedangkan Gambar 3b menunjukkan perubahan jumlah fitur pada solusi terbaik global.



Gambar 3. Konvergensi ACO: (a) perkembangan *composite score*, (b) jumlah fitur solusi terbaik

Berdasarkan Gambar 3, nilai *composite score* terbaik meningkat hingga mencapai 0,664 dan tidak mengalami peningkatan lagi setelah iterasi ke-84 sehingga proses dihentikan melalui mekanisme *early stopping*. Jumlah fitur pada solusi terbaik berubah secara dinamis selama proses pencarian sebelum akhirnya konvergen pada 17 fitur. Hasil ini menunjukkan bahwa ACO mampu menghasilkan subset fitur yang lebih ringkas dibandingkan SA.

Metode ACO menghasilkan nilai *composite score* terbaik sebesar 0,664 dengan jumlah fitur terpilih sebanyak 17 fitur. Dibandingkan dengan SA, metode ACO menghasilkan subset fitur yang lebih ringkas dengan tingkat reduksi sebesar 91,10% dari total fitur kandidat. Fitur yang terpilih juga didominasi oleh variabel yang berkaitan dengan riwayat rawat inap pasien, jenis admisi, spesialisasi medis, jenis terapi diabetes, serta status penggunaan obat diabetes. Hasil ini menunjukkan bahwa ACO mampu mengidentifikasi kombinasi fitur yang lebih kompak tanpa mengurangi kualitas solusi yang diperoleh.

Perbandingan kedua metode menunjukkan bahwa ACO menghasilkan nilai *composite score* yang lebih tinggi dibandingkan SA (0,664 dibandingkan 0,613) sekaligus menggunakan jumlah fitur yang lebih sedikit (17 dibandingkan 29 fitur). Temuan ini mengindikasikan bahwa ACO memiliki kemampuan eksplorasi ruang solusi yang lebih baik dalam menemukan subset fitur yang relevan pada dataset *diabetes readmission*. Oleh karena itu, subset fitur hasil seleksi ACO dan SA selanjutnya digunakan pada tahap pembangunan dan optimasi model RF untuk dievaluasi lebih lanjut.

Proses optimasi model RF bertujuan memperoleh kombinasi *hyperparameter* yang menghasilkan nilai ROC-AUC tertinggi pada data validasi. Hasil optimasi *hyperparameter* ditunjukkan pada Tabel 1. Kedua metode menghasilkan kombinasi *hyperparameter* yang berbeda, yang mengindikasikan bahwa masing-masing algoritma optimasi mengeksplorasi ruang solusi secara berbeda untuk menemukan konfigurasi RF yang optimal. Model RF-ACO menghasilkan ROC-AUC sebesar 0,586, sedikit lebih tinggi dibandingkan RF-SA yang memperoleh nilai 0,578. Hasil tersebut menunjukkan bahwa konfigurasi *hyperparameter* yang diperoleh melalui ACO mampu menghasilkan kinerja model yang lebih baik dibandingkan konfigurasi yang diperoleh melalui SA.

Tabel 1. Perbandingan hasil optimasi *hyperparameter* model RF-SA dan RF-ACO

Karakteristik	RF-SA	RF-ACO
n_estimators	100	100
max_depth	8	30
min_samples_split	10	20
min_samples_leaf	2	1
max_features	log2	0,3
ROC-AUC	0,578	0,586


Setelah diperoleh konfigurasi *hyperparameter* terbaik untuk masing-masing model, tahap selanjutnya adalah mengevaluasi kinerja model pada data uji. Evaluasi dilakukan dengan membandingkan model RF *baseline*, RF-SA, dan RF-ACO menggunakan metrik utama penelitian, yaitu *composite score*. Selain itu, nilai ROC-AUC dan tingkat reduksi fitur juga dianalisis karena kedua komponen tersebut menjadi dasar dalam perhitungan *composite score*. Hasil perbandingan ketiga model tersebut disajikan pada Tabel 2.

Tabel 2. Hasil evaluasi model pada data uji

Model	ROC-AUC	Jumlah Fitur	Composite Score
RF (<i>Baseline</i>)	0,647	191	0,582
RF-SA	0,588	29	0,614
RF-ACO	0,591	17	0,623

Berdasarkan metrik utama penelitian, yaitu *composite score*, RF-ACO menghasilkan nilai tertinggi sebesar 0,623, diikuti oleh RF-SA sebesar 0,614 dan model *baseline* sebesar 0,582. Hasil ini menunjukkan bahwa RF-ACO memberikan keseimbangan terbaik antara performa klasifikasi dan kompleksitas model. Meskipun model *baseline* memiliki nilai ROC-AUC yang lebih tinggi, penggunaan seluruh fitur menyebabkan nilai *composite score* yang diperoleh lebih rendah. Sebaliknya, RF-ACO mampu mencapai nilai *composite score* tertinggi dengan reduksi fitur sebesar 91,10%. Temuan ini menunjukkan bahwa pendekatan ACO efektif dalam menghasilkan model yang lebih sederhana dengan penurunan performa prediksi yang relatif kecil.

Untuk memperoleh pemahaman yang lebih mendalam mengenai kontribusi masing-masing fitur terhadap prediksi model, dilakukan analisis menggunakan SHAP. Metode ini memungkinkan interpretasi model dengan mengukur besarnya pengaruh setiap fitur terhadap output prediksi. Gambar 4 menunjukkan nilai *mean absolute SHAP* dari 17 fitur yang dipertahankan oleh RF-ACO sebagai model yang paling efektif. Semakin besar nilai SHAP suatu fitur, semakin besar pula kontribusinya terhadap keputusan prediksi model.

Gambar 4. Tingkat kepentingan fitur berdasarkan *mean absolute SHAP* pada model RF-ACO

Gambar 4 menunjukkan bahwa variabel *number_inpatient* merupakan fitur yang paling berpengaruh dalam memprediksi *readmission*, ditunjukkan oleh nilai SHAP yang jauh lebih tinggi dibandingkan fitur lainnya. Temuan ini mengindikasikan bahwa riwayat rawat inap pasien menjadi faktor penting dalam menentukan kemungkinan pasien kembali dirawat setelah keluar dari rumah sakit. Selain itu, fitur *diabetesMed_Yes*, *payer_code_MC*, *admission_type_id_1*, dan *medical_specialty_InternalMedicine* juga memiliki kontribusi yang relatif besar terhadap prediksi model. Secara umum, fitur-fitur yang memiliki pengaruh tinggi didominasi oleh informasi terkait riwayat pelayanan kesehatan, karakteristik admisi, spesialisasi medis, serta penggunaan obat diabetes. Hasil ini sejalan dengan proses seleksi fitur sebelumnya yang menunjukkan bahwa faktor klinis dan pemanfaatan layanan kesehatan merupakan komponen utama dalam memprediksi kejadian *readmission*. Sementara itu, beberapa fitur lain seperti *gender_infrequent_sklearn*, *glyburide-metformin_infrequent_sklearn*, dan *admission_type_id_infrequent_sklearn* memiliki nilai SHAP yang relatif kecil, tetapi tetap dipertahankan karena memberikan kontribusi tambahan terhadap performa model secara keseluruhan. Dengan demikian, hasil interpretasi SHAP menunjukkan bahwa RF-ACO tidak hanya mampu menghasilkan model yang lebih sederhana melalui reduksi fitur yang substansial, tetapi juga mempertahankan fitur-fitur yang paling relevan dan informatif dalam menjelaskan risiko *readmission* pasien diabetes.

PEMBAHASAN

Hasil penelitian menunjukkan bahwa ACO menghasilkan *composite score* yang lebih tinggi dibandingkan SA pada tahap seleksi fitur, yaitu sebesar 0,664 dibandingkan 0,613. Selain itu, ACO hanya memilih 17 fitur dari total 191 fitur yang tersedia, sedangkan SA memilih 29 fitur. Dalam konteks prediksi *diabetes readmission*, proses seleksi fitur menjadi penting karena dataset mengandung banyak atribut yang berasal dari karakteristik pasien, riwayat perawatan, diagnosis, prosedur medis, serta informasi administratif rumah sakit. Menurut Strack et al. (2014), faktor-faktor tersebut secara bersama-sama memengaruhi kemungkinan pasien mengalami rawat inap kembali sehingga menghasilkan ruang fitur yang besar dan kompleks. Kondisi tersebut meningkatkan kemungkinan adanya fitur yang redundan maupun kurang relevan terhadap proses prediksi.

Hasil penelitian ini menunjukkan bahwa ACO mampu menghasilkan subset fitur yang lebih ringkas tanpa mengorbankan kualitas solusi secara signifikan. Reduksi fitur yang dihasilkan ACO mencapai 91,10%, sedangkan SA menghasilkan reduksi sebesar 84,82%. Ashokkumar et al. (2025) menyatakan bahwa seleksi fitur merupakan tahapan penting dalam klasifikasi *machine learning* karena mampu menghilangkan fitur yang tidak relevan dan mempertahankan kualitas prediksi model. Temuan penelitian ini mendukung pernyataan tersebut karena meskipun jumlah fitur berkurang secara signifikan, performa prediksi model tetap berada pada tingkat yang kompetitif.

Keunggulan ACO pada penelitian ini dapat dijelaskan melalui mekanisme pencarian berbasis koloni semut yang memanfaatkan informasi feromon (*pheromone trails*) untuk memandu proses pencarian solusi. Solusi yang menghasilkan kualitas lebih baik akan memperoleh penguatan feromon sehingga memiliki peluang lebih besar untuk dipilih pada iterasi berikutnya. Mekanisme ini memungkinkan proses pencarian memanfaatkan pengalaman dari solusi-solusi sebelumnya sekaligus tetap melakukan eksplorasi terhadap ruang solusi yang belum dieksplorasi. Saraç dan Özel (2014) menjelaskan bahwa karakteristik tersebut membuat ACO efektif dalam menemukan subset fitur yang relevan pada permasalahan berdimensi tinggi. Hasil penelitian ini mendukung temuan tersebut karena ACO mampu menghasilkan reduksi fitur sebesar 91,10%, lebih tinggi dibandingkan SA yang menghasilkan reduksi fitur sebesar 84,82%.

Pada tahap optimasi *hyperparameter*, ACO kembali menghasilkan nilai *composite score* pada data validasi yang sedikit lebih tinggi dibandingkan SA, yaitu sebesar 0,605 dan 0,619. Meskipun perbedaannya relatif kecil, hasil tersebut menunjukkan bahwa ACO mampu mempertahankan kualitas pencarian yang konsisten pada dua tahap optimasi yang berbeda. O'Boyle et al. (2008) menyatakan bahwa ACO memiliki kemampuan untuk melakukan pencarian kombinatorial secara efektif karena proses pencarian dilakukan secara kolektif oleh sejumlah agen yang saling berbagi informasi melalui pembaruan feromon. Karakteristik ini memungkinkan ACO mengeksplorasi lebih banyak kombinasi parameter dibandingkan pendekatan pencarian tunggal seperti SA.

Evaluasi pada data uji menunjukkan bahwa model RF *baseline* menghasilkan nilai ROC-AUC tertinggi sebesar 0,647. Namun demikian, model tersebut menggunakan seluruh 191 fitur yang tersedia. Sebaliknya, model RF-ACO hanya menggunakan 17 fitur dengan nilai ROC-AUC sebesar 0,591, sedangkan RF-SA menggunakan 29 fitur dengan nilai ROC-AUC sebesar 0,588. Hasil ini menunjukkan bahwa proses seleksi fitur memang menyebabkan penurunan performa prediksi dibandingkan model *baseline*. Akan tetapi, penurunan tersebut relatif kecil jika dibandingkan dengan jumlah fitur yang berhasil dieliminasi. Dengan kata lain, sebagian besar informasi yang diperlukan untuk melakukan prediksi masih dapat dipertahankan meskipun lebih dari 80% fitur dihilangkan.

Temuan tersebut sejalan dengan prinsip dasar RF yang dikemukakan oleh Breiman (2001), yaitu bahwa performa model tidak selalu meningkat seiring bertambahnya jumlah fitur yang digunakan. Kehadiran fitur yang tidak relevan atau redundan justru dapat meningkatkan kompleksitas model tanpa memberikan peningkatan informasi yang berarti. Oleh karena itu, penggunaan subset fitur yang lebih kecil dapat menjadi alternatif yang lebih efisien apabila mampu mempertahankan performa prediksi pada tingkat yang dapat diterima.

Meskipun ROC-AUC memberikan gambaran kemampuan diskriminasi model, metrik tersebut belum mempertimbangkan aspek efisiensi model yang menjadi tujuan utama proses seleksi fitur. Oleh karena itu, evaluasi selanjutnya dilakukan menggunakan *composite score* yang menggabungkan performa prediksi dan tingkat reduksi fitur dalam satu ukuran. Penelitian ini menggunakan *composite score* sebagai metrik utama evaluasi dengan menggabungkan ROC-AUC dan reduksi fitur melalui persamaan 6, dengan nilai $w = 0,9$. Pemilihan bobot tersebut menunjukkan bahwa performa prediksi tetap menjadi prioritas utama, sementara kompleksitas model digunakan

sebagai faktor pendukung dalam proses evaluasi. Berdasarkan metrik tersebut, RF-ACO menghasilkan *composite score* tertinggi sebesar 0,623, diikuti oleh RF-SA sebesar 0,614 dan model *baseline* sebesar 0,582. Hasil ini menunjukkan bahwa model dengan ROC-AUC tertinggi tidak selalu menjadi model terbaik apabila efisiensi model turut dipertimbangkan.

Temuan penelitian ini juga mendukung hasil penelitian Lifandali et al. (2023) yang menunjukkan bahwa kombinasi ACO dan RF mampu menghasilkan model yang lebih efisien melalui identifikasi fitur-fitur yang paling relevan. Meskipun konteks permasalahan yang diteliti berbeda, kedua penelitian menunjukkan bahwa ACO efektif digunakan untuk mengurangi dimensi data tanpa menyebabkan penurunan performa yang terlalu besar. Kontribusi utama penelitian ini adalah menunjukkan bahwa pendekatan optimasi berbasis metaheuristik dapat diterapkan secara terintegrasi pada tahap seleksi fitur dan optimasi *hyperparameter* untuk menghasilkan model prediksi yang lebih efisien. Pada kasus *diabetes readmission*, penggunaan ACO berhasil mengurangi jumlah fitur dari 191 menjadi 17 fitur dengan tetap mempertahankan ROC-AUC sebesar 0,591 dan menghasilkan *composite score* tertinggi. Temuan ini menunjukkan bahwa peningkatan efisiensi model dapat dicapai tanpa harus mempertahankan seluruh fitur yang tersedia.

Meskipun hasil penelitian ini menunjukkan bahwa pendekatan yang diusulkan mampu menghasilkan model yang lebih sederhana dengan performa yang tetap kompetitif, beberapa keterbatasan masih perlu diperhatikan. Salah satunya berkaitan dengan penggunaan *composite score* sebagai metrik evaluasi utama. Nilai bobot yang digunakan dalam penelitian ini ditetapkan sebesar ($w = 0,95$) sehingga penilaian model masih lebih menekankan aspek performa prediksi dibandingkan reduksi fitur. Jika bobot yang digunakan berbeda, maka hasil evaluasi dan peringkat model yang diperoleh juga dapat berubah. Selain itu, seluruh eksperimen hanya dilakukan menggunakan algoritma RF. Oleh karena itu, belum dapat diketahui apakah subset fitur yang dihasilkan oleh SA dan ACO akan memberikan manfaat yang sama ketika diterapkan pada algoritma klasifikasi lain. Penelitian ini juga terbatas pada satu dataset *diabetes readmission* sehingga hasil yang diperoleh belum tentu dapat langsung digeneralisasikan ke dataset kesehatan lain yang memiliki karakteristik berbeda. Kondisi ini sejalan dengan temuan Guyon dan Elisseeff (2003) yang menyatakan bahwa keberhasilan suatu metode seleksi fitur sering kali dipengaruhi oleh karakteristik data serta model pembelajaran yang digunakan.

SIMPULAN

Penelitian ini menunjukkan bahwa ACO lebih efektif dibandingkan SA dalam meningkatkan kinerja RF untuk prediksi *readmission* pasien diabetes berdasarkan keseimbangan antara performa prediksi dan efisiensi fitur. ACO menghasilkan model terbaik dengan memilih 17 fitur dari 191 fitur kandidat, mencapai tingkat reduksi fitur sebesar 91,10%, serta memperoleh nilai *composite score tertinggi* sebesar 0,623 dibandingkan RF-SA sebesar 0,614 dan RF *baseline* sebesar 0,582. Dengan demikian, ACO dapat dipertimbangkan sebagai metode optimasi yang lebih sesuai untuk pengembangan model prediksi *readmission* pada data rekam medis berdimensi tinggi karena mampu menghasilkan model yang lebih ringkas dengan kinerja yang tetap kompetitif. Berdasarkan temuan tersebut, penerapan ACO dapat digunakan sebagai pendekatan operasional dalam proses seleksi fitur dan optimasi model prediksi di lingkungan pelayanan kesehatan yang memerlukan efisiensi komputasi dan penggunaan fitur yang lebih sederhana. Penelitian selanjutnya disarankan untuk menguji metode ini pada dataset dan populasi yang berbeda serta membandingkannya dengan algoritma optimasi lain atau pendekatan optimasi multiobjektif agar diperoleh model dengan kemampuan generalisasi yang lebih baik. Selain itu, analisis sensitivitas terhadap bobot *composite score* serta pengujian subset fitur pada algoritma klasifikasi lain dapat dilakukan untuk mengevaluasi konsistensi dan robustitas pendekatan yang diusulkan.

DAFTAR PUSTAKA

- Ashokkumar, P., Kumar, S., & Khan, M. (2025). Ant Colony Optimization for feature selection in breast cancer classification. *Egyptian Informatics Journal*, 32(November), 100847. <https://doi.org/10.1016/j.eij.2025.100847>
- Balasubramanian, K., Williams, A., & Butun, I. (2025). *Feature Importance Guided Random Forest Learning with Simulated Annealing Based Hyperparameter Tuning*. 1–10.
- Boyle, N. M. O., Palmer, D. S., Nigsch, F., Mitchell, J. B. O., & Mitchell, J. B. O. (2008). *Simultaneous*

feature selection and parameter optimisation using an artificial ant colony : case study of melting point prediction. 15, 1–15. <https://doi.org/10.1186/1752-153X-2-21>

- Breiman, L. (2001). *RANDOM FORESTS.* *Machine Learnin*, 45(1), 5–32. <https://doi.org/10.1023/A:1010922404324>
- Cherian, I., Tamboli, A. I., Pandey, A., & Manchanda, M. (2024). *A Comparative Study of Simulated Annealing and Ant Colony Optimization for Optimizing MRI-Based Alzheimer ' s Disease Classification.* 12, 464–475.
- Genitsaridi, I., Salpea, P., Salim, A., Sajjadi, S. F., Tomic, D., James, S., Thirunavukkarasu, S., Issaka, A., Chen, L., Basit, A., Luk, A. O. Y., Ma, R. C. W., Mbanya, J., Ramachandran, A., Wild, S. H., Duncan, B. B., Boyko, E. J., & Magliano, D. J. (2025). 11th edition of the IDF Diabetes Atlas : global , regional , and national diabetes prevalence estimates for 2024 and projections for 2050. *THE LANCET Diabetes & Endocrinology*, 14(2), 149–156. [https://doi.org/10.1016/S2213-8587\(25\)00299-2](https://doi.org/10.1016/S2213-8587(25)00299-2)
- Guyon, I., & Elisseeff, A. (2003). An Introduction to Variable and Feature Selection. *Journal of Machine learning Research*, 3, 1157–1182.
- Lifandali, O., Abghour, N., & Chiba, Z. (2023). Feature Selection Using a Combination of Ant Colony Optimization Feature Selection Using a Combination of To Ant Colony Forest Optimization and *Random Forest* Algorithms Applied Isolation Based and *Random Forest* Intrusion Algorithms Applied To Isolation Fo. *Procedia Computer Science*, 220, 796–805. <https://doi.org/10.1016/j.procs.2023.03.106>
- Mafarja, M. M., & Mirjalili, S. (2018). Whale Optimization Approaches for Wrapper Feature Selection. *Applied Soft Computing*, 62, 441–453. <https://doi.org/10.1016/j.asoc.2017.11.006>
- Prasetyowati, M. I., Maulidevi, N. U., & Surendro, K. (2022). *The accuracy of Random Forest performance can be improved by conducting a feature selection with a balancing strategy.* 1–15. <https://doi.org/10.7717/peerj-cs.1041>
- Salim, S. S., & Ibrahim, A. A. (2026). A *Machine learning* Approach for Predicting 30-Day Hospital Readmission in Patients with Diabetes. *Healthcare*, 14(9), 1185. <https://doi.org/10.3390/healthcare14091185>
- Saraç, E., & Özel, S. A. (2014). *An Ant Colony Optimization Based Feature Selection for Web Page Classification.* 2014. <https://doi.org/10.1155/2014/649260>
- Strack, B., Deshazo, J. P., Gennings, C., Olmo, J. L., Ventura, S., Cios, K. J., & Clore, J. N. (2014). *Impact of HbA1c Measurement on Hospital Readmission Rates : Analysis of 70 , 000 Clinical Database Patient Records.* 2014. <https://doi.org/10.1155/2014/781670>
- Syaiful, A., Sartono, B., Afendi, F. M., Anisa, R., & Salim, A. (2021). Feature Selection Using Simulated Annealing with Optimal Neighborhood Approach. *Journal of Physics: Conference Series*, 1752(1), 012030. <https://doi.org/10.1088/1742-6596/1752/1/012030>
- Wardana, M. D., Budiman, I., Indriani, F., & Nugrahadi, D. T. (2025). *Implementation of Ant Colony Optimization in Obesity Level Classification Using Random Forest.* 6(5), 3543–3557.